

Grado de Estadística y Empresa

Curso 2025/2026

Análisis Multivariante

Trabajo Análisis Multivariante – Tarea 2

**An Fu Pham
Xinle Zhang
Jacobo Sanz Parada**

ÍNDICE

1. INTRODUCCIÓN.....	3
2. ANÁLISIS DE COMPONENTES PRINCIPALES	3
3. ANÁLISIS CANÓNICO DE POBLACIONES (MANOVA).....	9
4. CONCLUSIONES	17
Referencias.....	18
Anexo: Código R	19

1. INTRODUCCIÓN

Para la realización de la segunda tarea de este trabajo de Análisis Multivariante conviene recordar tanto el conjunto de datos elegido como la selección de variables escogidas en la primera tarea. El conjunto de datos de este trabajo es el mismo que el usado en la Tarea 1, se trata de datos provenientes de la Encuesta de Presupuestos Familiares del año 2024 realizada por el Instituto Nacional de Estadística (INE). El conjunto de datos seleccionado consta de 1000 hogares seleccionados aleatoriamente mediante una muestra aleatoria simple y de 11 variables, que se pueden dividir en:

- 6 variables cuantitativas: Gasto en Comida; Gasto en Vivienda; Gasto en Salud; Gasto en Ocio, espectáculos y cultura; Gasto en Hoteles, cafés, restaurantes; Gasto Total anual del hogar.
- 2 variables binarias: Otros ingresos, Asalariado.
- 3 variables categóricas: Nivel de estudios del sustentador principal, Tamaño del municipio, Tamaño del hogar.

Además, cabe recordar que en la tarea anterior de este trabajo se llevó a cabo una transformación no lineal, $\log(x+1)$, para corregir los problemas de heterocedasticidad y de asimetría que tenían las variables cuantitativas seleccionadas. Por lo tanto, para esta segunda parte se utilizó el conjunto de datos transformado.

2. ANÁLISIS DE COMPONENTES PRINCIPALES

2.1 Cálculo de porcentajes de variabilidad explicada

El Análisis de Componentes Principales (PCA) es una técnica de reducción de dimensión cuyo objetivo es resumir la información contenida en varias variables cuantitativas correlacionadas mediante un número menor de variables nuevas, llamadas componentes principales. Estas componentes son combinaciones lineales de las variables originales, son incorreladas entre sí y se ordenan de forma que la primera explica la mayor parte posible de la variabilidad total, la segunda la mayor parte de la variabilidad restante, y así sucesivamente.

Para la realización de este apartado se utilizaron las seis variables cuantitativas de gasto del hogar ya descritas en la introducción del trabajo: gasto en comida, gasto en vivienda, gasto en sanidad, gasto en ocio, gasto en restaurantes y gasto total anual del hogar, sobre una muestra aleatoria simple de 1000 hogares procedentes de la Encuesta de Presupuestos Familiares 2024. Tal y como se recoge en el código final proporcionado, antes de aplicar el PCA las variables continuas se expresaron en miles de euros y, posteriormente, se transformaron mediante $\log(x + 1)$, es decir, se trabajó realmente con la transformación

$$x_{ij}^{(\log)} = \log\left(\frac{x_{ij}}{1000} + 1\right) \quad i = 1, \dots, n, j = 1, \dots, p$$

2.2 Resumen de medidas y planteamiento de análisis

Sea $X = (x_{ij})$ la matriz de datos original, con $n = 1000$ hogares y $p = 6$ variables cuantitativas. En primer lugar, las variables de gasto se reescalaron a miles de euros: $x_{ij}^{(m)} = \frac{x_{ij}}{1000}$

y, a continuación, se aplicó la transformación logarítmica:

$$x_{ij}^{(\log)} = \log(x_{ij}^{(m)} + 1) = \log\left(\frac{x_{ij}}{1000} + 1\right)$$

Posteriormente, dado que las variables presentan distinta dispersión y se desea que todas contribuyan en igualdad de condiciones al análisis, se procedió a su estandarización. Si $\bar{x}_j^{(\log)}$ y s_j representan, respectivamente, la media y la desviación típica de la variable j -ésima transformada, entonces:

$$z_{ij} = \frac{x_{ij}^{(\log)} - \bar{x}_j^{(\log)}}{s_j}$$

Denotando por Z la matriz de datos tipificados, el PCA se realiza sobre la matriz de correlaciones:

$$R = \frac{1}{n} Z' H_n Z \quad H_n = I_n - \frac{1}{n} \mathbf{1}_n \mathbf{1}_n'$$

Esta elección es coherente con la teoría del método, ya que el centrado es obligatorio y la estandarización evita que una sola variable domine el análisis únicamente por su escala o dispersión.

La obtención de las componentes principales puede hacerse mediante la descomposición espectral de:

$$R = T \Lambda T'$$

donde $T = (t_1, \dots, t_p)$ es una matriz ortogonal formada por los autovectores de R , y

$$\Lambda = \text{diag}(\lambda_1, \lambda_2, \dots, \lambda_p) \quad \lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p \geq 0$$

es la matriz diagonal de autovalores. Equivalentemente, el PCA puede calcularse mediante descomposición en valores singulares (SVD), que es el procedimiento computacional empleado en la práctica y el que utiliza la función `prcomp` de R, basada precisamente en esta descomposición.

La j -ésima componente principal se define como:

$$Y_j = Z t_j, j = 1, \dots, p$$

o, en forma matricial,

$$Y = ZT$$

Estas componentes verifican:

$$Var(Y_j) = \lambda_j, Cov(Y_j, Y_k) = 0 \text{ si } j \neq k$$

Es decir, cada autovalor mide la varianza explicada por su componente asociada y las componentes principales están incorreladas entre sí. Como se trabaja con variables tipificadas, la variabilidad total del sistema es:

$$VT(Z) = tr(R) = \sum_{j=1}^p p\lambda_j = p = 6$$

y el porcentaje de variabilidad explicado por la (q)-ésima componente viene dado por:

$$Pq = \frac{\lambda_q}{\sum_{j=1}^p \lambda_j} \cdot 100$$

mientras que la variabilidad acumulada hasta la componente (q) se calcula como:

$$PAq = \frac{\sum_{j=1}^q \lambda_j}{\sum_{j=1}^p p\lambda_j} \cdot 100$$

2.3 Cálculo de porcentajes de variabilidad explicada


Tras realizar la estandarización de las variables cuantitativas y aplicar la descomposición en valores singulares, se obtuvieron los siguientes resultados:

Componente	Autovalor (λ)	Varianza (%)	Acumulado (%)
CP1	2.9555	49.26	49.26
CP2	0.9301	15.50	64.76
CP3	0.7956	13.26	78.02
CP4	0.6869	11.45	89.47
CP5	0.5558	9.64	98.73
CP6	0.0761	1.27	100.00

Por tanto, la primera componente principal explica el **49.26%** de la variabilidad total y la segunda el **15.50%**, alcanzándose un **64.76% acumulado** con las dos primeras dimensiones. Si además se retuviese una tercera componente, la variabilidad acumulada ascendería hasta el **78.02%**.

Desde el punto de vista práctico, estos resultados muestran que la primera dimensión concentra una parte muy importante de la información, mientras que la segunda aporta una cantidad adicional moderada. Por ello, la representación bidimensional sigue siendo útil con fines descriptivos y gráficos, aunque debe tenerse en cuenta que una parte no despreciable de la variabilidad total queda fuera del plano formado por CP1 y CP2. En términos geométricos, el PCA busca precisamente proyectar los individuos sobre un subespacio de baja dimensión maximizando la varianza explicada en dicho plano.

2.4 Determinación del número de componentes



La determinación del número de componentes a conservar puede apoyarse en varios criterios. En los apuntes de la asignatura se mencionan, entre otros, el porcentaje acumulado de variabilidad explicada, el criterio de Kaiser, la modificación de Jolliffe y el scree test de Cattell. Asimismo, el review de Greenacre et al. destaca el scree plot como una de las herramientas habituales para decidir la dimensionalidad relevante del PCA.

En este trabajo, el criterio del porcentaje acumulado indica que las dos primeras componentes explican el 64.76% de la variabilidad total, mientras que tres componentes elevan dicho porcentaje al 78.02%. Esto sugiere que una representación bidimensional es razonable para resumir la estructura principal de los datos, aunque una solución tridimensional recogería una fracción mayor de la información disponible.

Por otra parte, el criterio de Kaiser recomienda conservar aquellas componentes cuyo autovalor sea superior a 1. En este caso, únicamente la primera componente cumple esta condición:

$$\lambda_1 = 2.9555 > 1$$

mientras que:

$$\lambda_2 = 0.9301 < 1, \lambda_3 = 0.7956 < 1, \lambda_4 = 0.6869 < 1, \lambda_5 = 0.5558 < 1, \lambda_6 = 0.0671 < 1$$

Por tanto, de forma estricta, el criterio de Kaiser sugeriría conservar solo una componente principal. Sin embargo, dado que el objetivo del PCA en este trabajo no es únicamente resumir numéricamente la información, sino también facilitar su representación gráfica e interpretación económica, resulta razonable trabajar con las dos primeras componentes principales. Así, CP1 recogería la dimensión dominante del sistema y CP2 aportaría información complementaria sobre la estructura interna del gasto, siempre que sus cargas permitan una interpretación sustantiva clara.

En consecuencia, en este trabajo se opta por interpretar principalmente el plano formado por CP1 y CP2, sin perder de vista que la primera componente es claramente dominante y que la segunda debe entenderse como una dimensión complementaria más que como un eje de peso comparable al primero.

2.5 Cálculo y obtención de los componentes principales

Conviene recordar que el signo de las componentes principales es arbitrario: multiplicar una componente por -1 no altera su contenido informativo, sino únicamente la orientación del eje. Por ello, para facilitar la interpretación económica de los resultados, se adopta la orientación de los ejes más intuitiva.

Denotando por $Z_1, \dots, Z_6$ las variables tipificadas correspondientes, respectivamente, al gasto en comida, vivienda, sanidad, ocio, restaurantes y gasto total, las dos primeras componentes principales pueden expresarse aproximadamente como:

$$CP1 = 0.3561Z_1 + 0.4695Z_2 + 0.3069Z_3 + 0.3753Z_4 + 0.3570Z_5 + 0.5388Z_6$$

$$CP2 = -0.3844Z_1 - 0.4132Z_2 + 0.1832Z_3 + 0.4923Z_4 + 0.5949Z_5 - 0.2274Z_6$$

Además, dado que se trabaja con variables tipificadas, la correlación entre la variable original Z_i y la componente principal CP_j viene dada por:

$$\text{corr}(Z_i, CP_j) = t_{ij} \sqrt{\lambda_j}$$

donde t_{ij} representa el elemento i,j del autovector correspondiente. Asimismo, la contribución de cada variable a la construcción de una componente puede analizarse mediante los cuadrados de los coeficientes del autovector, ya que:

$$\sum_{i=1}^p t_{ij}^2 = 1$$


por lo que cuanto mayor sea t_{ij}^2 , mayor será la contribución de la variable i a la componente j . Esta lectura de contribuciones mediante cuadrados de las cargas coincide con la interpretación numérica estándar del PCA descrita en el review metodológico de Greenacre et al..

En la primera componente principal, las mayores cargas corresponden al **gasto total** (0.5388) y al **gasto en vivienda** (0.4695) seguidos del **gasto en ocio** (0.3753), del **gasto en restaurantes** (0.3570) y del **gasto en comida** (0.3561). En la segunda componente principal, la mayor carga positiva corresponde al **gasto en restaurantes**, (0.5949) seguida del **gasto en ocio** (0.4923), mientras que las mayores cargas negativas corresponden al **gasto en vivienda** (-0.4132) y al **gasto en comida** (-0.3844)

A continuación, se muestran las cargas de las variables en las dos primeras componentes:

Variable	CP1	CP2
Gasto comida	0.3561	-0.3844
Gasto vivienda	0.4695	-0.4132
Gasto Sanidad	0.3069	0.4923
Gasto Ocio	0.3753	-0.4803
Gasto Restaurante	0.3570	0.5949
Gasto total	0.5388	-0.2274

2.6 Interpretación de resultados y conclusiones del PCA



La interpretación de las componentes principales debe apoyarse tanto en las cargas anteriores como en la estructura de correlaciones entre las variables originales. En el propio trabajo, el gráfico matricial de dispersión ya mostraba relaciones positivas entre las distintas variables de gasto, lo que justifica plenamente la aplicación del PCA y la existencia de una dimensión común subyacente en el comportamiento de consumo de los hogares.

La **primera componente principal** puede interpretarse claramente como un eje de **nivel general de gasto o riqueza de consumo**. En efecto, todas las variables presentan cargas positivas en esta dimensión, lo que indica que la componente recoge el patrón común compartido por todas ellas. Además, las mayores ponderaciones corresponden al gasto total anual del hogar y al gasto en vivienda, lo que sugiere que CP1 resume principalmente la intensidad global del consumo. En términos prácticos, los hogares con puntuaciones altas en CP1 son aquellos que presentan niveles elevados de gasto en la mayoría de las partidas, mientras que los hogares con puntuaciones bajas muestran un volumen total de consumo menor. Por tanto, CP1 mide esencialmente **cuánto gasta el hogar en conjunto**.

La **segunda componente principal**, en cambio, recoge diferencias en la **composición del gasto**. Sus cargas muestran una oposición entre, por un lado, el **gasto en ocio** y el **gasto en restaurantes**, acompañados en menor medida por el **gasto en sanidad**, y, por otro lado, el **gasto en comida** y el **gasto en vivienda**, junto con una aportación negativa más moderada del **gasto total**. Esto significa que CP2 no diferencia tanto entre hogares que gastan más o menos en términos absolutos, sino entre hogares que, para un determinado nivel de gasto, distribuyen de forma distinta su presupuesto. En un extremo del eje se situarían hogares con mayor peso relativo de ocio y restauración, mientras que en el extremo opuesto aparecerían hogares con una estructura de gasto relativamente más orientada a comida y vivienda.

Desde el punto de vista geométrico, esta interpretación es coherente con la lectura del biplot en PCA. Según la formulación estándar del método, las coordenadas de los individuos en el plano principal vienen dadas por las dos primeras columnas de la matriz $Y = ZT$, mientras que las variables se representan mediante vectores cuyas direcciones permiten interpretar el sentido de aumento de cada gasto y los contrastes entre ellos. Cuando dos vectores apuntan en direcciones parecidas, sugieren asociación positiva; cuando apuntan en direcciones opuestas, reflejan un contraste entre variables dentro del plano principal.

En conjunto, el Análisis de Componentes Principales permite concluir que la estructura de gasto de los hogares puede resumirse de manera razonable mediante dos dimensiones principales. La primera componente recoge el **volumen global de gasto**, mientras que la segunda refleja la **estructura relativa del presupuesto familiar**, o dicho de otro modo, el tipo de partidas en las que el hogar tiende a concentrar relativamente más su consumo. No obstante, debe tenerse en cuenta que la primera componente es claramente dominante, ya que explica por sí sola el **49.26%** de la variabilidad total, frente al **15.50%** explicado por la segunda. Por ello, la mayor parte de la información del sistema se encuentra asociada a un único eje principal, mientras que la segunda dimensión debe entenderse como un complemento interpretativo útil para describir matices en la composición del gasto.


3. ANÁLISIS CANÓNICO DE POBLACIONES (MANOVA)

El MANOVA busca representar grupos de individuos o poblaciones de forma óptima a lo largo de unos ejes canónicos (ortogonales), de manera que la dispersión entre estos grupos sea máxima en relación a la dispersión dentro de los grupos, pudiendo estudiar mejor las relaciones entre los distintos grupos.

Por lo tanto, para la realización de este apartado se procedió a separar la población original (el conjunto de datos seleccionado) en diferentes grupos de poblaciones en función de una variable. La variable de clasificación seleccionada ha sido la variable multiclase: “Nivel de estudios del sustentador principal”. Cabe destacar que, con respecto a la anterior tarea realizada, se escogió una variable indicadora del nivel de formación, pero con categorías más reducidas (seleccionado ‘ESTUDREDSP’ en vez de ‘ESTUDIOSSP’), pasando de las 8 categorías originales a solamente 4, facilitando así la posterior interpretación de los resultados. Dichas categorías son:

1. Inferior a la primera etapa de educación secundaria
2. Primera etapa de educación secundaria
3. Segunda etapa de educación secundaria
4. Educación superior.

Antes de proceder con los cálculos para la obtención de los ejes canónicos de poblaciones, se realizó un gráfico matricial de dispersión condicional al Nivel de Estudios del sustentador principal. Esta representación permite obtener una primera impresión de la separación entre los grupos en el espacio original de las variables, así como de las relaciones entre las variables de gasto y su posible dependencia del nivel de estudios.



Del gráfico se observa que el grupo 4 (Educación Superior), presenta distribuciones desplazadas hacia valores más altos en todas las variables de gasto, mientras que en el grupo 1 (Inferior a Secundaria) se concentra en valores más bajos. Por su parte, los grupos 2 y 3 muestran distribuciones intermedias y más solapadas entre sí, lo que sugiere que habrá una mayor diferencia entre los niveles educativos 1 y 4. Además se aprecian correlaciones positivas entre todas las variables de gasto, lo que justifica el uso de un enfoque multivariante y motiva el análisis canónico de poblaciones que se desarrolla a continuación.

3.1. Medidas de resumen y descomposición de la variabilidad

En primer lugar, se procedió al cálculo del vector de medias global, la matriz de covarianzas global, y las matrices de dispersión entre grupos y dentro de los grupos.

- Vector de medias global: $\bar{x} = \frac{1}{n} X' 1_n$
 $\bar{x} = (7,8395; 8,9036; 5,375; 5,572; 6,22; 10,02)$

- Matriz de Covarianzas global: $S = \frac{1}{n} X' H_n X$, siendo $H = I_n - \frac{1}{n}$

$$S = \begin{bmatrix} 2,7168 & 0,5657 & 1,041 & 1,2126 & 1,03 & 0,764 \\ 0,5657 & 0,814 & 0,664 & 0,7923 & 0,771 & 0,73615 \\ 1,041 & 0,664 & 7,4 & 1,917 & 2,035 & 0,9522 \\ 1,2126 & 0,7923 & 1,9169 & 7,49 & 3,607 & 1,17 \\ 1,03 & 0,771 & 2,035 & 3,607 & 9,051 & 1,2839 \\ 0,764 & 0,73615 & 0,9522 & 1,17 & 1,2839 & 0,8467 \end{bmatrix}$$

- Matriz de Dispersión entre los grupos: $B = \sum_{\alpha=1}^g n_{\alpha}(\bar{x}_{\alpha} - \bar{x})(\bar{x}_{\alpha} - \bar{x})'$
- $B = \begin{bmatrix} 12,33 & 12,41 & 33,213 & 88,597 & 85,105 & 17,686 \\ 12,41 & 18,33 & 41,716 & 118,09 & 114,927 & 25,51 \\ 33,213 & 41,716 & 101,704 & 276,675 & 266,786 & 58,063 \\ 88,597 & 118,09 & 276,675 & 798,786 & 781,63 & 168,517 \\ 85,105 & 114,927 & 266,786 & 781,63 & 767,51 & 163,037 \\ 17,686 & 25,510 & 58,063 & 168,517 & 165,037 & 36,106 \end{bmatrix}$

Matriz de Dispersión dentro de los Grupos: $W = \sum_{\alpha=1}^g n_{\alpha}S_{\alpha}$

$$W = \begin{bmatrix} 2704,504 & 553,27 & 1008,35 & 1124,044 & 945,671 & 746,56 \\ 553,27 & 795,9026 & 622,23 & 674,22 & 656,845 & 710,64 \\ 1008,35 & 622,23 & 7297,58 & 1640,24 & 1768,96 & 894,188 \\ 1124,04 & 674,22 & 1640,24 & 6690,75 & 2825,715 & 1009,27 \\ 945,67 & 656,845 & 1768,96 & 2825,715 & 8283,5 & 1118,93 \\ 746,56 & 710,646 & 894,188 & 1009,27 & 1118,93 & 810,62 \end{bmatrix}$$

Siendo por tanto la Matriz de Dispersión Total, $T = B + W = X'H_nX$

$$T = \begin{bmatrix} 2716,83 & 565,68 & 1041,56 & 1212,641 & 1030,77 & 764,25 \\ 565,68 & 814,23 & 663,946 & 792,311 & 771,77 & 736,157 \\ 1041,56 & 663,946 & 7399,28 & 1916,914 & 2035,75 & 952,25 \\ 1212,641 & 792,311 & 1916,914 & 7489,54 & 3607,35 & 1177,787 \\ 1030,77 & 771,77 & 2035,75 & 3607,35 & 9051,01 & 1283,975 \\ 764,25 & 736,157 & 952,25 & 1177,787 & 1283,975 & 846,727 \end{bmatrix}$$

3.2. Contrastes de hipótesis y validación de supuestos:

Antes de proceder a la interpretación de los ejes canónicos, es fundamental verificar si los datos cumplen con los requisitos estadísticos que garantiza la validez de análisis por medio del **contraste de igualdad de matrices de covarianzas (test de Barlett)**.

El primer paso crítico es evaluar la homocedasticidad multi variante, es decir, si la dispersión de los gastos es similar en los cuatro grupos educativos definidos

Test de Barlett (Igualdad de Covarianzas)

$$H_0 : \Sigma_1 = \Sigma_2 = \Sigma_3 = \Sigma_4 \quad H_1 : \exists \alpha \neq \beta \text{ tal que } \Sigma_\alpha \neq \Sigma_\beta$$

El estadístico se transforma en una aproximación χ^2 :

$$M = -2\log\lambda_R = n\log|S| - \sum_{\alpha=1}^g n_\alpha \log|S_\alpha| \sim \chi_q^2, q = \frac{(g-1)p(p+1)}{2}$$

- Estadístico del contraste χ^2 , $M = 355,7246$
- Grados de libertad: $df = \frac{(g-1)p(p+1)}{2} = \frac{3 \times 6 \times 7}{2} = 63$
- P-valor: $Pr(\chi_{63}^2 > 355,7246) \approx 0$

Resultado del contraste: el test de Barlett multivariante arroja un p valor < 0.05 lo que nos obliga a rechazar la hipótesis nula de igualdad de matrices de covarianzas. Esto indica la presencia de heteroscedasticidad, sugiriendo que la variabilidad del gasto no es uniforme entre los hogares con distintos niveles de estudio.

Protocolo de verificación: ante este rechazo, se procedió a inspeccionar las matrices de covarianzas de cada grupo (S_1, S_2, S_3, S_4) elemento a elemento. Se observó que los signos de las correlaciones entre las categorías de gastos se mantienen constantes en todas las poblaciones.

$$S_1 = \begin{bmatrix} 3,762 & 0,298 & 1,09 & 1,253 & 1,013 & 0,67 \\ 0,298 & 0,677 & 0,38 & 0,219 & 0,44 & 0,5304 \\ 1,09 & 0,38 & 7,877 & 0,98 & 2,643 & 0,784 \\ 1,253 & 0,219 & 0,98 & 8,975 & 4,918 & 0,855 \\ 1,013 & 0,44 & 2,643 & 4,918 & 12,67 & 1,256 \\ 0,67 & 0,5304 & 0,784 & 0,855 & 1,256 & 0,681 \end{bmatrix}$$

$$S_2 = \begin{bmatrix} 3,1917 & 0,591 & 0,888 & 1,426 & 1,424 & 0,768 \\ 0,591 & 0,792 & 0,818 & 0,678 & 0,798 & 0,745 \\ 0,888 & 0,818 & 7,7 & 1,805 & 2,543 & 1,089 \\ 1,426 & 0,678 & 1,805 & 7,67 & 3,423 & 1,088 \\ 1,424 & 0,798 & 2,543 & 3,423 & 9,68 & 1,36 \\ 0,768 & 0,745 & 1,089 & 1,088 & 1,36 & 0,856 \end{bmatrix}$$

$$S_3 = \begin{bmatrix} 2,012 & 0,702 & 1,044 & 0,841 & 0,764 & 0,83 \\ 0,702 & 0,847 & 0,57 & 0,764 & 0,52 & 0,76 \\ 1,044 & 0,57 & 6,67 & 1,347 & 2,156 & 0,875 \\ 0,841 & 0,764 & 1,347 & 7,08 & 2,917 & 0,997 \\ 0,764 & 0,52 & 2,156 & 2,917 & 9,296 & 1,018 \\ 0,83 & 0,76 & 0,875 & 0,997 & 1,018 & 0,835 \end{bmatrix}$$

$$S_4 = \begin{bmatrix} 2,453 & 0,538 & 1,047 & 1,0588 & 0,7315 & 0,722 \\ 0,538 & 0,817 & 0,615 & 0,782 & 0,722 & 0,729 \\ 1,047 & 0,615 & 7,28 & 1,94 & 0,7864 & 0,827 \\ 1,0588 & 0,782 & 1,94 & 5,154 & 1,72 & 1,028 \\ 0,7315 & 0,722 & 1,7864 & 1,72 & 5,44 & 0,99 \\ 0,722 & 0,729 & 0,827 & 1,028 & 0,99 & 0,82 \end{bmatrix}$$

Decisión técnica: dado que la orientación de los elipsoides de concentraciones análoga en todos los grupos se determina que el análisis ser robusto. Por tanto, se decide continuar utilizando la matriz de covarianzas ponderada (*pooled-within-matrix*).

$$S_p = \frac{W}{n - g}$$

Donde W es la matriz de Dispersión entre los Grupos y n-g los grados de libertad

Contraste de Igualdad de Vectores de Medias (Lambda de Wilks)

Una vez validada la continuidad del estudio, evaluamos el nivel de formación del sustentador principal, realmente genera perfiles de consumo diferenciados.

$$H_0 : \mu_1 = \mu_2 = \mu_3 = \mu_4 \quad H_1 : \exists \alpha \neq \beta \text{ tal que } \mu_\alpha \neq \mu_\beta$$

Estadístico de contraste: se utiliza el estadístico Λ de Wilks , calculado como el cociente entre la dispersión dentro de los grupos y la dispersión total:

$$\Lambda = \frac{|W|}{|T|} = 0.8576 \approx \Lambda(p, n - g, g - 1) ,$$

$$a = n - g = 996, \quad b = g - 1 = 3$$

Transformación a F de Fisher (aproximación de Rao):

$$\gamma = \frac{pb - 2}{4} = \frac{6 \times 3 - 2}{4} = 4$$

$$\beta = \sqrt{\frac{p^2 b^2 - 4}{p^2 + b^2 - 5}} = \sqrt{\frac{6^2 \times 3^2 - 4}{6^2 + 3^2 - 5}} = \sqrt{\frac{320}{40}} = 2,828$$

$$\alpha = a + b - \frac{p + b + 1}{2} = 996 + 3 - \frac{6 + 3 + 1}{2} = 994$$

$$F_{Rao} = \frac{1 - \Lambda^{1/\beta}}{\Lambda^{1/\beta}} \cdot \frac{\alpha \cdot \beta - 2\gamma}{p \cdot b} = \frac{1 - 0.8576^{1/2,828}}{0.8258^{1/2,828}} \cdot \frac{992 \times 2,828 - 8}{18} \approx 8,688 \sim F_{pb, \alpha\beta-2\gamma} \\ \sim F_{18,2803}$$

Significación estadística proporcionada: El contraste arroja un p valor < 0.001, lo que permite rechazar con total confianza y hipótesis de igualdad de centros de gravedad entre grupos.

Conclusión socioeconómica: el valor de 0.8576 indica que una parte de la variabilidad entre los gastos del hogar (específicamente un 14.24% de la varianza capturada por el modelo) se explica por la pertenencia a un grupo educativo determinado. En términos prácticos, esto confirma que el nivel de estudios no solo influye en la cantidad total de dinero gastado, sino en la priorización y estructura de las categorías de consumo (comida, sanidad, ocio, etc.)

3.3. Cálculo y obtención de las variables canónicas

Posteriormente se procedió a la obtención de los ejes canónicos. Estos ejes se resolvieron mediante la diagonalización relativa de B respecto de S_p , la cuál es la matriz de covarianzas dentro de los grupos y que se calcula como $S_p = \frac{W}{n-g}$. Resultando en $Bv_i = \lambda_i S_p v_i$, $i = 1, 2, \dots, p$, cumpliendo la condición de normalización de $v_i' S_p v_i = \begin{cases} 1, & \text{si } i = j \\ 0, & \text{si } i \neq j \end{cases}$.

Se obtuvieron los siguientes resultados:

$$S_p = \begin{bmatrix} 2,715 & 0,555 & 1,012 & 1,1286 & 0,9495 & 0,7496 \\ 0,555 & 0,8 & 0,6247 & 0,677 & 0,6594 & 0,7135 \\ 1,012 & 0,6247 & 7,327 & 1,6468 & 1,7761 & 0,897 \\ 1,1286 & 0,677 & 1,6468 & 6,717 & 2,837 & 1,013 \\ 0,9495 & 0,6594 & 1,7761 & 2,837 & 8,3167 & 1,123 \\ 0,7496 & 0,7135 & 0,897 & 1,013 & 1,123 & 0,814 \end{bmatrix}$$

$\Lambda = \text{diag}(158,105; 4,136; 2,0836; 8,81 \times 10^{-16}; -4,80427 \times 10^{-14}; -9,1983 \times 10^{-14})$, siendo Λ , una

matriz diagonal con los autovalores $\lambda_i, i = 1, 2, \dots, p$, ordenados de mayor a menor.

$$V = \begin{bmatrix} 0,4094 & -0,222 & -0,1932 & 0,089 & 0,11002 & -0,3401 \\ -0,4217 & -0,5961 & 1 & -0,7418 & -0,6987 & 0,384 \\ -0,0315 & -0,0976 & 0,088 & -0,02 & 0,056 & 0,0832 \\ -1 & -0,0546 & -0,0027 & 0,095 & -0,0735 & 0,1015 \\ -0,664 & -0,011 & -0,082 & -0,204 & -0,067 & 0,06285 \\ -0,0192 & 1 & -0,3505 & 1 & 1 & -1 \end{bmatrix}$$

Para la realización del análisis nos quedamos con sólo los 3 primeros ejes y los 3 primeros autovalores, dado que $m = \min(g - 1, p) = \min(3, 6) = 3$. Además, tendremos que estandarizar la matriz de autovectores, $V = [v_1, v_2, v_3]$, para que se cumpla la condición de normalidad expresada anteriormente.

Se realiza tal que: $V = V_{anterior} \left(\frac{1}{\sqrt{\text{diag}(V' S_p V)}} \right)$

$$V = \begin{bmatrix} 0,108 & -0,4948 & -0,2786 \\ -0,111 & -1,3273 & 1,441 \\ -0,008 & -0,217 & 0,1273 \\ -0,2644 & -0,1217 & -0,0039 \\ -0,1756 & -0,0245 & -0,11827 \\ -0,0051 & 2,2266 & -0,505 \end{bmatrix}$$

Posteriormente, se procedió al cálculo de las variables canónicas definidas como combinaciones de las variables originales $X_1, X_2, \dots, X_6$: $Y_j = Xv_j$, $j = 1, 2, 3$. En forma matricial: $Y_{n \times m} = XV_{p \times m}$. Obteniendo finalmente las coordenadas de los individuos en función de las nuevas variables canónicas:

$$Y = \begin{bmatrix} -2,3956 & 4,0344 & 5,975 \\ 0,2264 & 4,06 & 6,187480 \\ -1,0757 & 4,053 & 4,736 \\ \dots & \dots & \dots \\ \dots & \dots & \dots \\ -2,79 & 5,238 & 5,495 \end{bmatrix}$$


Además, los porcentajes de variabilidad explicada por los 3 ejes canónicos se calcularon así:

$$P_q = \frac{\lambda_q}{\lambda_1 + \lambda_2 + \lambda_3} \times 100$$

Eje	Autovalor	Porcentaje Variabilidad	Acumulado
1	158,1050	96,21	96,21
2	4,1363	2,52	98,73
3	2,0836	1,27	100

Además, se calcularon los vectores de medias en las nuevas coordenadas obtenidas: $\bar{y}_\alpha = \bar{x}'_\alpha V$, $\alpha = 1, 2, 3, 4$, siendo cada fila el vector de medias de un grupo (individuo medio) en el espacio canónico.

$$\bar{Y} = \begin{bmatrix} -1,987 & 4,676 & 5,567 \\ -2,623 & 4,619 & 5,437 \\ -2,81 & 4,502 & 5,54 \\ -3,196 & 4,66 & 5,53 \end{bmatrix}$$



También se realizó el gráfico de representación de las coordenadas canónicas a través de los 2 primeros ejes, que son los que explican la mayor parte de la variabilidad explicada, donde se resaltaron las posiciones de los individuos medios en cada grupo. Sin embargo, al haber un gran número de individuos por grupo, el gráfico puede llegar a ser poco claro. Por lo que para obtener una representación más clara y precisa de las diferencias entre grupos, se pueden representar estos grupos construyendo regiones de confianza alrededor de los individuos medios.


- Grupo 1 (Inferior): (-1,987; 4,676)
- Grupo 2 (Primera etapa Secundaria): (-2,623; 4,619)
- Grupo 3 (Segunda etapa Secundaria): (-2,81; 4,502)
- Grupo 4 (Superior): (-3,196; 4,66)

3.4. Cálculo de las regiones de confianza al 95%

Se calcularon posteriormente los radios de confianza para cada grupo al $\epsilon = 5\%$, $r_{\epsilon}(i) = \sqrt{F_{\epsilon} \frac{(n-g)p}{n-g-p+1} \frac{1}{n_i}}$, siendo F_{ϵ} , el percentil $(1 - \epsilon) \times 100$, de la ley F de Fisher con p , $n - g - p + 1$ grados de libertad.

Grupo	n_i	Radio
1	134	0,3080
2	250	0,2255
3	221	0,2398
4	395	0,1794

Al calcular los radios de confianza al 95 %, se observa que las regiones resultantes son totalmente disjuntas. Esto confirma que las diferencias entre los perfiles de gastos son robustas y que los grupos educativos representan poblaciones con comportamientos de consumo nítidamente diferenciados.



Interpretación de Resultados

El gráfico de regiones de confianza muestra una separación clara y prácticamente lineal a lo largo del primer eje canónico, que explica el 96.2% de la variabilidad entre grupos. Los cuatro grupos se ordenan de derecha a izquierda según el nivel educativo creciente, lo que indica que este primer eje captura esencialmente un gradiente educativo en los patrones de gasto.

La distancia entre el grupo 1 (Inferior a Secundaria, $\bar{y}_1 = -1.987$) y el grupo 4 (Educación Superior, $\bar{y}_4 = -3.196$) en el primer eje canónico confirma que el nivel educativo es un factor determinante en la estructura del gasto del hogar. Los grupos 2 y 3, en cambio, presentan regiones

solapadas, lo que sugiere que no existen diferencias significativas en los patrones de consumo entre la primera y segunda etapa de secundaria.

En conclusión, las regiones de confianza al 95% de los grupos 1 y 4 son completamente disjuntas entre sí y respecto al resto, validando que estos dos grupos representan poblaciones con hábitos de consumo claramente diferenciados. Los grupos 2 y 3 presentan un solapamiento parcial, indicando que sus patrones de gasto no difieren de forma concluyente.


3.5. Conclusiones del Análisis Canónico

El análisis canónico de poblaciones aplicado sobre los cuatro grupos educativos permite extraer las siguientes conclusiones.

En primer lugar, la descomposición de la variabilidad entre grupos muestra que prácticamente toda la **separación entre los perfiles de gasto** queda recogida en el primer eje canónico (96,21%), siendo el segundo y tercer eje marginales (2,52% y 1,27% respectivamente). Esto indica que las diferencias entre grupos educativos en cuanto a comportamiento de consumo se pueden representar con facilidad utilizando sólo los 2 primeros ejes canónicos.

En segundo lugar, el contraste de Bartlett rechaza la igualdad de matrices de covarianzas entre grupos, si bien la inspección de los signos de las matrices (S_1, S_2, S_3, S_4) confirma que la estructura de relaciones entre variables se mantiene constante en todos los grupos.

En tercer lugar, el contraste de Lambda de Wilks ($\Lambda = 0.8576, p < 0.001$) permite rechazar la igualdad de vectores de medias. Además, los grupos 1 (Inferior a Secundaria) y 4 (Educación Superior) presentan regiones de confianza al 95% completamente alejadas, confirmando diferencias significativas en sus perfiles de consumo.



En conjunto, el **nivel educativo del sustentador principal** se revela como un **factor discriminante significativo**, aunque de efecto moderado, en la estructura del gasto familiar.

4. CONCLUSIONES

El presente trabajo ha abordado el análisis multivariante del gasto de los hogares españoles a partir de los microdatos de la Encuesta de Presupuestos Familiares 2024, combinando dos técnicas complementarias: el Análisis de Componentes Principales y el Análisis Canónico de Poblaciones.

El **Análisis de Componentes Principales** ha permitido **reducir la dimensionalidad** del espacio de variables de gasto a dos componentes principales que explican conjuntamente el **64,76%** de la variabilidad total. La primera componente, claramente dominante con un 49,26%, recoge el volumen global de gasto del hogar, siendo el gasto total y el gasto en vivienda las variables con mayor peso. La segunda componente, con un 15.50%, refleja la composición relativa del presupuesto, oponiendo el gasto en ocio y restauración frente al gasto en comida y vivienda.

El **Análisis Canónico** ha complementado esta visión al incorporar la variable educativa como factor de clasificación, revelando que el nivel de estudios del sustentador principal genera **perfiles de consumo diferenciados**. La separación entre grupos queda capturada en 2 ejes canónicos que concentran el 98,73% de la variabilidad entre grupos, lo que refuerza el carácter esencialmente bidimensional de las diferencias educativas en el comportamiento de consumo.

Ambos análisis convergen en una conclusión común: el comportamiento de gasto de los hogares españoles está estructurado principalmente por una dimensión de volumen o nivel económico, que explica la mayor parte de la variabilidad tanto en el PCA como en la separación entre grupos educativos del análisis canónico. No obstante, la variabilidad no explicada por estas dos técnicas sugiere que otros factores —como el tamaño del hogar o el tamaño del municipio— podrían complementar el análisis y enriquecer la comprensión del comportamiento de consumo familiar.

Referencias

Grané, A. (2026). *Tema 3. Análisis de Componentes Principales*. [Apuntes de clase]. Aula Global, Universidad Carlos III de Madrid.

<https://aulaglobal.uc3m.es/mod/resource/view.php?id=5791366>

Grané, A. (2026). *Tema 4. Análisis Canónico de Poblaciones (MANOVA)*. [Apuntes de clase]. Aula Global, Universidad Carlos III de Madrid.

<https://aulaglobal.uc3m.es/mod/resource/view.php?id=5791366>

Greenacre, M., Groenen, P.J.F., Hastie, T. *et al.* Principal component analysis. *Nat Rev Methods Primers* **2**, 100 (2022). <https://doi.org/10.1038/s43586-022-00184-w>

R Core Team (2025). R: A Language and Environment for Statistical Computing. R Foundation for Statistical Computing, Vienna, Austria. <https://www.r-project.org/>

Schloerke B, Cook D, Larmarange J, Briatte F, Marbach M, Thoen E, Elberg A, Crowley J (2025). GGally: Extension to 'ggplot2'. doi:10.32614/CRAN.package.GGally
<<https://doi.org/10.32614/CRAN.package.GGally>>, R package version 2.4.0,
<<https://CRAN.R-project.org/package=GGally>>.

Hasselman B, Lapack authors (2019). geigen: Calculate Generalized Eigenvalues, the Generalized Schur Decomposition and the Generalized Singular Value Decomposition of a Matrix Pair with Lapack. doi:10.32614/CRAN.package.geigen.
<<https://doi.org/10.32614/CRAN.package.geigen>>, R package version 2.3,
<<https://CRAN.R-project.org/package=geigen>>.

Wickham H (2016). *ggplot2: Elegant Graphics for Data Analysis*. Springer-Verlag New York. ISBN 978-3-319-24277-4, <https://ggplot2.tidyverse.org>.

Anexo: Código R

TAREA 2 - TRABAJO ANÁLISIS MULTIVARIANTE

```
library(ggplot2)
library(GGally)

library(geigen)

load("EPFhogar_2024.RData")

datos <- Microdatos

datos_sub <- datos[, c(
  "GASTOTGR01", "GASTOTGR04", "GASTOTGR06", "GASTOTGR09",
  "GASTOTGR11", "GASTOT", "OTROIN",
  "CAJENA", "ESTUDREDSP", "TAMAMU", "TAMANO"
)]

colnames(datos_sub) <- c(
  "Gasto_Comida", "Gasto_Vivienda", "Gasto_Sanidad", "Gasto_Ocio",
  "Gasto_Restaurante", "Gasto_total", "Otros_ingresos",
  "Asalariado", "Estudios", "Tam_Municipio", "Tam_Hogar"
)

datos_limpios <- datos_sub

datos_limpios$Otros_bin <- ifelse(datos_limpios$Otros_ingresos == 1, 1, 0)
datos_limpios$Asalariado_bin <- ifelse(datos_limpios$Asalariado == 1, 1, 0)

datos_limpios$Estudios <- as.factor(datos_limpios$Estudios)
datos_limpios$Tam_Municipio <- as.factor(datos_limpios$Tam_Municipio)
datos_limpios$Tam_Hogar <- as.factor(datos_limpios$Tam_Hogar)

datos_limpios$Asalariado <- NULL
datos_limpios$Otros_ingresos <- NULL

set.seed(1234)
filas <- sample(nrow(datos_limpios), 1000)
datos_final <- datos_limpios[filas, ]

str(datos_final)

summary(datos_final)

datos_num <- datos_final[, sapply(datos_final, is.numeric)]
vars_continuas <- c("Gasto_Comida", "Gasto_Vivienda", 'Gasto_Sanidad',
  "Gasto_Ocio",
  'Gasto_Restaurante', "Gasto_total")

datos_num[vars_continuas] <- datos_num[vars_continuas] / 1000
```

```
datos_trans <- datos_num
datos_trans[vars_continuas] <- log(datos_trans[vars_continuas]+1)
datos_trans_n <- as.matrix(datos_trans[, vars_continuas])
```

```
#-----
# ANÁLISIS DE COMPONENTES PRINCIPALES - PCA
```

```
Z_pca <- scale(datos_trans_n, center = TRUE, scale = TRUE)
pca <- prcomp(Z_pca, center = FALSE, scale. = FALSE)
```

```
autovalores <- pca$sdev^2
var_exp <- 100 * autovalores / sum(autovalores)
var_acum <- cumsum(var_exp)
```

```
tabla_pca <- data.frame(
  Componente = paste0("CP", 1:length(autovalores)),
  Autovalor = round(autovalores, 4),
  Varianza = round(var_exp, 2),
  Acumulada = round(var_acum, 2)
)
```

```
tabla_cargas <- data.frame(
  Variable = rownames(pca$rotation),
  CP1 = round(-pca$rotation[, 1], 4),
  CP2 = round(-pca$rotation[, 2], 4)
)
```

```
print(tabla_pca)
print(tabla_cargas)
```

```
# =====
# GRÁFICA 1: SCREE PLOT
```

```

# =====
plot(var_exp, type = "b", pch = 19,
      xlab = "Componente principal",
      ylab = "Porcentaje de varianza explicada",
      main = "Scree plot del PCA")
abline(h = 100 / ncol(Z_pca), lty = 2)

# =====
# GRÁFICA 2: BIPLLOT
# =====
# =====
# BIPLLOT LIMPIO
# =====

# Coordinadas de individuos
scores <- as.data.frame(pca$x[, 1:2])
colnames(scores) <- c("CP1", "CP2")
scores$Estudios <- datos_final$Estudios

# Coordinadas de variables
loadings <- as.data.frame(-pca$rotation[, 1:2])
colnames(loadings) <- c("CP1", "CP2")
loadings$Variable <- rownames(loadings)

# Escalado de flechas para que se vean bien junto a los puntos
mult <- min(
  (max(scores$CP1) - min(scores$CP1)) / (max(loadings$CP1) - min(loadings$CP1)),
  (max(scores$CP2) - min(scores$CP2)) / (max(loadings$CP2) - min(loadings$CP2))
) * 0.35

```

```

loadings$CP1 <- loadings$CP1 * mult
loadings$CP2 <- loadings$CP2 * mult

# Gráfico
ggplot() +
  geom_point(data = scores,
             aes(x = CP1, y = CP2, color = Estudios),
             alpha = 0.35, size = 1.2) +
  geom_segment(data = loadings,
              aes(x = 0, y = 0, xend = CP1, yend = CP2),
              arrow = arrow(length = unit(0.2, "cm")),
              linewidth = 0.8) +
  geom_text(data = loadings,
           aes(x = CP1, y = CP2, label = Variable),
           vjust = -0.7, size = 4) +
  labs(
    title = "Biplot del PCA",
    x = paste0("CP1 (", round(var_exp[1], 2), "%)"),
    y = paste0("CP2 (", round(var_exp[2], 2), "%)")
  ) +
  coord_equal() +
  theme_bw()

# =====
# GRÁFICA 3: INDIVIDUOS EN EL PLANO PRINCIPAL
# =====

scores <- as.data.frame(pca$x[, 1:2])
colnames(scores) <- c("CP1", "CP2")
scores$Estudios <- datos_final$Estudios

```

```

graf_individuos <- ggplot(scores, aes(x = CP1, y = CP2, color = Estudios)) +
  geom_point(alpha = 0.6) +
  labs(
    title = "Hogares en el plano principal",
    x = paste0("CP1 (", round(var_exp[1], 2), "%)"),
    y = paste0("CP2 (", round(var_exp[2], 2), "%)")
  ) +
  coord_equal() +
  theme_bw()

print(graf_individuos)

# =====
# GRÁFICA 4: CARGAS DE LAS VARIABLES
# =====

loadings <- as.data.frame(-pca$rotation[, 1:2])
colnames(loadings) <- c("CP1", "CP2")
loadings$Variable <- rownames(loadings)

graf_cargas <- ggplot(loadings) +
  geom_segment(aes(x = 0, y = 0, xend = CP1, yend = CP2),
    arrow = arrow(length = grid::unit(0.2, "cm"))) +
  geom_text(aes(x = CP1, y = CP2, label = Variable), vjust = -0.5) +
  labs(
    title = "Cargas de las variables en el plano principal",
    x = "CP1",
    y = "CP2"
  ) +
  coord_equal() +
  theme_bw()

```

```

print(graf_cargas)

#-----
# ANÁLISIS CANÓNICO DE POBLACIONES - MANOVA

# Variable multicategórica seleccionada: Nivel de estudios del sustentador principal
gsize = c(sum(datos_final$Estudios == 1), sum(datos_final$Estudios == 2),
          sum(datos_final$Estudios == 3), sum(datos_final$Estudios == 4))

grupo = c(rep(1,gsize[1]), rep(2,gsize[2]), rep(3,gsize[3]), rep(4,gsize[4]))

# Gráfico de Dispersión matricial condicional
ggpairs(datos_trans_n, columns = 1:6,
        mapping = aes(color = factor(datos_final$Estudios,
                                     levels = 1:4,
                                     labels = c("1 - Inferior a Secundaria", "2 - Primera etapa Secundaria",
                                                "3 - Segunda etapa Secundaria", "4 - Educación Superior"))),
        fill = factor(datos_final$Estudios,
                      levels = 1:4,
                      labels = c("1 - Inferior a Secundaria", "2 - Primera etapa Secundaria",
                                "3 - Segunda etapa Secundaria", "4 - Educación Superior"))),
        upper = list(continuous = wrap("points", alpha = 0.7, size = 0.6)),
        lower = list(continuous = wrap("points", alpha = 0.7, size = 0.6)),
        diag = list(continuous = wrap("densityDiag", alpha = 0.7)),
        title = "Gráfico de dispersión matricial condicionado al Nivel de Estudios del Sustentador Principal",
        legend = 1 # <-- esto activa la leyenda
) +
  labs(color = "Nivel de estudios", fill = "Nivel de estudios") +
  theme_bw() +
  theme(
    text = element_text(size = 16), axis.text = element_text(size = 12),
    axis.title = element_text(size = 14), strip.text = element_text(size = 14),
    legend.text = element_text(size = 13), legend.title = element_text(size = 14)
  )

ggsave("dispersion_estudios.png", width = 20, height = 15, dpi = 300)

```

```

orden <- order(datos_final$Estudios)
X <- datos_trans_n[orden, ] # datos ordenados según el nivel de estudio

n <- nrow(X)
mmX <- colMeans(X)

# Matriz de centrado global
Hn <- diag(n) - matrix(1, n, n) / n

# Covarianza global
S_global <- t(X) %*% Hn %*% X / n

p <- ncol(X)
g <- length(gsize)
n0 <- cumsum(gsize)
n0_start <- c(1, n0[-g] + 1)

# Medias por grupo
mX <- matrix(0, nrow = g, ncol = p)
for (i in 1:g) {
  mX[i, ] <- colMeans(X[n0_start[i]:n0[i], , drop = FALSE])
}

# Matriz de Dispersión entre Grupos
B <- matrix(0, p, p)
for (i in 1:g) {
  diff_i <- matrix(mX[i, ] - mmX, ncol = 1)
  B <- B + gsize[i] * diff_i %*% t(diff_i)
}

# Matriz de Dispersión dentro de Los Grupos
W <- matrix(0, p, p)
for (i in 1:g) {
  Xi <- X[n0_start[i]:n0[i], , drop = FALSE]
  ni <- gsize[i]
  Hi <- diag(ni) - matrix(1, ni, ni) / ni
  W <- W + t(Xi) %*% Hi %*% Xi
}

# Matriz de Dispersión Total
T_mat <- B + W
T_mat2 <- t(X) %*% Hn %*% X # debe coincidir con B + W

# Test 1 - Igualdad de medias (Lambda de Wilks)
lambda <- det(W) / det(W + B)

wilkstof <- function(L, p, a, b) {
  alpha <- a + b - (p + b + 1) / 2
  beta <- sqrt((p^2 * b^2 - 4) / (p^2 + b^2 - 5))
  gamma <- (p * b - 2) / 4
  m <- p * b
  n_val <- alpha * beta - 2 * gamma
  n_val <- round(n_val)
}

```

```

F_val <- ((1 - L^(1/beta)) / (L^(1/beta))) * n_val / m
  return(list(F = F_val, m = m, n = n_val))
}

wilkstof(lambda, 6, 996, 3)

## $F
## [1] 8.688557
##
## $m
## [1] 18
##
## $n
## [1] 2803

pf(8.688557,2803,18,lower.tail = FALSE)

## [1] 1.526534e-06

# Test 2 – Igualdad de covarianzas (Bartlett)
logH1 <- 0

for (i in 1:g) {
  Xi    <- X[n0_start[i]:n0[i], , drop = FALSE]

  Si    <- t(Xi) %*% (diag(gsize[i]) - matrix(1, gsize[i], gsize[i]) /
    gsize[i]) %*% Xi / gsize[i]

  logH1 <- logH1 + gsize[i] * log(det(Si))
}

chi    <- abs(n * log(det(S_global)) - logH1)
q      <- (g - 1) * p * (p + 1) / 2
p_valor <- 1 - pchisq(chi, q)

# Matrices de covarianza por grupo
cov_grupos <- lapply(1:g, function(i) {
  cov(X[n0_start[i]:n0[i], , drop = FALSE])
})

# Matrices de signos por grupo
signos <- lapply(cov_grupos, sign)

S_pooled <- W / (n - g)
eig_result <- geigen::geigen(B, S_pooled, symmetric = FALSE)
lambda    <- eig_result$values
idx <- order(lambda, decreasing = TRUE)
lambda    <- lambda[idx]
V    <- eig_result$vectors[, idx]
m <- min(g - 1, p)
V <- V[, 1:m, drop = FALSE]

```

```

lambda <- lambda[1:m]
VtSV <- t(V) %*% S_pooled %*% V
V <- V %*% diag(1 / sqrt(diag(VtSV)))

Y <- X %*% V # coordenadas canónicas de los individuos (n x m)
mY <- mX %*% V # vectores de medias en nuevas coordenadas (g x m)

percent <- lambda / sum(lambda) * 100
acum <- cumsum(percent)

data.frame(
  Eje = paste0("Can", 1:m),
  Autovalor = round(lambda, 4),
  Variabilidad = round(percent, 2),
  Acumulado = round(acum, 2)
)

##      Eje Autovalor Variabilidad Acumulado
## 1 Can1  158.1050      96.21      96.21
## 2 Can2    4.1363       2.52      98.73
## 3 Can3    2.0836       1.27     100.00

grupo_vec <- rep(1:g, times = gsize)
df_Y <- data.frame(
  Can1 = Y[, 1],
  Can2 = Y[, 2],
  Grupo = factor(grupo_vec,
    labels = c("1 - Inferior a Secundaria",
               "2 - Primera etapa Secundaria",
               "3 - Segunda etapa Secundaria",
               "4 - Educación Superior"))
)
df_mY <- data.frame(
  Can1 = mY[, 1],
  Can2 = mY[, 2],
  Grupo = factor(1:g),
  Label = as.character(1:g)
)

ggplot(df_Y, aes(x = Can1, y = Can2, color = Grupo)) +
  geom_point(alpha = 0.5) +
  geom_point(data = df_mY, shape = 17, size = 4, color = "black") +
  geom_text(data = df_mY, aes(label = Grupo), vjust = -1,
    color = "black", fontface = "bold") +
  labs(
    title = paste0("Coordenadas canónicas (", round(acum[2], 1), "% va",
    riabilidad acumulada)'),
    x = paste0("1er eje canónico (", round(percent[1], 1), "%)"),
    y = paste0("2º eje canónico (", round(percent[2], 1), "%)"),
  ) +
  theme_bw() +
  theme(

```

```

    text = element_text(size = 16), axis.text = element_text(size = 1
2),
    axis.title = element_text(size = 14), strip.text = element_text(s
ize = 14),
    legend.text = element_text(size = 13), legend.title = element_text
(size = 14)
  )
}

ggsave("coordenadas_indiv_medios.png", width = 15, height = 10, dpi =
150)

# Regiones de Confianza
alpha <- 0.05
radios <- sapply(1:g, function(i) {
  ni <- gsize[i]
  sqrt((p * (n - g)) / ((n - g - p + 1) * ni) * qf(1 - alpha, p, n - g
- p + 1))
})

data.frame(Grupo = 1:g, n_i = gsize, Radio = round(radios, 4))

##   Grupo n_i  Radio
## 1     1 134 0.3080
## 2     2 250 0.2255
## 3     3 221 0.2398
## 4     4 395 0.1794

# Puntos del circulo
theta <- seq(0, 2 * pi, length.out = 314)

df_circulos <- data.frame(
  x = c(outer(cos(theta), radios)) + rep(mY[, 1], each = length(th
eta)),
  y = c(outer(sin(theta), radios)) + rep(mY[, 2], each = length(th
eta)),
  Grupo = factor(rep(1:g, each = length(theta)),
    labels = c("1 - Inferior a Secundaria", "2 - Primera e
tapa Secundaria",
              "3 - Segunda etapa Secundaria", "4 - Educa
ción Superior"))
)

ggplot() +
  geom_path(data = df_circulos, aes(x = x, y = y, color = Grupo),
    linewidth = 1) +
  geom_point(data = df_mY, aes(x = Can1, y = Can2, color = factor(Grup
o,
                        labels = c("1 - Inferior a Secundaria",
"2 - Primera etapa Secundaria",
                                "3 - Segunda etapa Secundaria", "
4 - Educación Superior"))),
    shape = 17, size = 4) +
  geom_text(data = df_mY, aes(x = Can1, y = Can2, label = Label),
    vjust = -1, fontface = "bold", size = 5) +

```

```

labs(
  title = paste0("Regiones de confianza al 95% (", round(acum[2], 1)
, "% variabilidad acumulada)"),
  x      = paste0("1er eje canónico (", round(percent[1], 1), "%)"),
  y      = paste0("2º eje canónico  (", round(percent[2], 1), "%)"),
  color = "Nivel de estudios"
) +
theme_bw() +
theme(
  text = element_text(size = 16), axis.text = element_text(size = 12
),
  axis.title    = element_text(size = 14), legend.text  = element_text
t(size = 13),
  legend.title = element_text(size = 14)
)
ggsave("regiones_confianza.png", width = 15, height = 10, dpi = 150)

```