

Grado de Estadística y Empresa

Curso 2025/2026

Análisis Multivariante

Trabajo Análisis Multivariante – Tarea 3

**An Fu Pham
Xinle Zhang
Jacobo Sanz Parada**

ÍNDICE

1.	INTRODUCCIÓN.....	3
1.1.	MATRIZ DE DISTANCIAS	3
2.	ANÁLISIS DE COORDENADAS PRINCIPALES	4
2.1.	Representación gráfica de las coordenadas principales	5
2.2.	Variabilidad explicada por las coordenadas principales	6
2.3.	Identificación de las variables subyacentes mediante correlaciones cruzadas	7
2.4.	Perfiles socioeconómicos en el espacio MDS.....	9
2.5.	Conclusiones del análisis MDS	14
3.	CLASIFICACIÓN JERÁRQUICA.....	15
3.1.	Elección del número de grupos.....	15
3.2.	Resultados de la clasificación	16
3.3.	Perfil cualitativo de los grupos.....	18
3.4.	Comparación con el análisis MDS.....	19
3.5.	Hipótesis y condiciones de aplicación.....	20
3.6.	Conclusiones de la clasificación	20
	BIBLIOGRAFÍA.....	21
	ANEXO: CÓDIGO R	22

1. INTRODUCCIÓN

Para la realización de esta tercera tarea del trabajo de Análisis Multivariante conviene recordar tanto el conjunto de datos elegido como la selección de variables escogidas y utilizadas a lo largo de las tareas anteriores. El conjunto de datos sigue siendo el mismo, se trata de datos provenientes de la Encuesta de Presupuestos Familiares del año 2024 realizada por el Instituto Nacional de Estadística (INE). El conjunto de datos seleccionado consta de 1000 hogares seleccionados mediante muestreo aleatorio simple y de 11 variables que se desglosan de la siguiente manera:

- 6 variables cuantitativas: Gasto en Comida; Gasto en Vivienda; Gasto en Salud; Gasto en Ocio, espectáculos y cultura; Gasto en Hoteles, cafés, restaurantes; Gasto Total anual del hogar.
- 2 variables binarias: Otros ingresos, Asalariado.
- 3 variables categóricas: Nivel de estudios del sustentador principal, Tamaño del municipio, Tamaño del hogar.

Cabe recordar también, que en la primera tarea se llevó a cabo una transformación no lineal, $\log(x+1)$, para corregir los problemas de heterocedasticidad y de asimetría que tenían las variables cuantitativas seleccionadas. Por lo tanto, para esta parte también se utilizaron las variables cuantitativas ya transformadas. Previo a la transformación logarítmica, se reescalaron los datos cuantitativos, para que estuviesen en unidades de miles de euros, manteniendo así una coherencia con la información real.

Para esta parte del trabajo, en la que se realizará un Análisis de Coordenadas Principales (MDS) y se aplicarán técnicas de Clasificación se utilizarán todas las variables seleccionadas, tanto las de tipo cuantitativo, las de tipo binario y las categóricas o multiclase.

1.1. MATRIZ DE DISTANCIAS

Para la realización de los distintos apartados de esta parte del trabajo es necesario calcular una matriz de distancias entre las variables del conjunto de datos. La distancia seleccionada, y dado que se procederá a trabajar con datos de tipo mixto, es la distancia de G-Gower (Grané et al., 2021). Se eligió esta distancia, porque la distancia de Gower original tiene un inconveniente dado que otorga más peso a las variables de tipo cualitativo que a las variables cuantitativas, esto puede dar lugar a resultados que puedan no ser del todo correctos y ser interpretados de manera deficiente. Por ello, se eligió la generalización de la distancia de Gower, ya que esta, sí tiene en cuenta la estructura de correlaciones entre las variables cuantitativas.

La matriz de cuadrados de distancias utilizando la distancia de Gower generalizada o G-Gower se define así:

$$D^{(2)} = \sum_{k=1}^3 \frac{1}{V(\delta_k)} D_k^{(2)},$$

donde $D_k^{(2)} = \left(\delta_k^2(x_i, x_j) \right)_{1 \leq i, j \leq n}$,

y $V(\delta_k)$ es la variabilidad geométrica de D_k , para $k = 1, 2, 3$.

Se calcularán diferentes distancias para los distintos tipos de datos: para las variables cuantitativas se utilizará la Distancia de Mahalanobis, para las variables binarias se utilizará la distancia

asociada al coeficiente de Jaccard y para las variables categóricas la distancia de Hamming. Combinándolas, se tiene lugar a la distancia de G-Gower.

Se obtuvo así la matriz de cuadrados de distancias de dimensión 1000x1000 al estar considerando los 1000 hogares de la muestra realizada. A continuación, se presenta la submatriz correspondiente a los primeros 5 individuos de la muestra para ilustrar la estructura de disimilitud inicial

$$D^{(2)} = \begin{bmatrix} 0 & 2,036 & 2,137 & 1,89 & 1,797 \\ 2,036 & 0 & 2,4 & 1,621 & 0,987 \\ 2,137 & 2,4 & 0 & 2,21 & 2,406 \\ 1,89 & 1,621 & 2,21 & 0 & 2,01 \\ 1,797 & 0,987 & 2,406 & 2,01 & 0 \end{bmatrix}$$

2. ANÁLISIS DE COORDENADAS PRINCIPALES

El Análisis de Coordenadas Principales tiene como objetivo principal obtener una representación euclídea, de los elementos de un conjunto de objetos ϵ . Para ello, se necesita una matriz D de distancias, ya calculada en la sección anterior, sobre el conjunto de datos seleccionado.

La representación euclídea, de dimensión $p \geq 0$, es una configuración de n puntos $y_1, y_2, y_3, \dots, y_n$ del espacio euclídeo, $\mathbb{R}^p$, donde se verifica que las distancias entre las nuevas coordenadas de individuos son las mismas que en D. Es decir:

$$\delta_{i,j}^2 = \|y_i - y_j\|^2 = \sum_{k=1}^p (y_{ik} - y_{jk})^2 = (y_i - y_j)'(y_i - y_j), 1 \leq i, j \leq n$$

Para poder obtener la representación euclídea, este análisis se centrará en encontrar las coordenadas o ejes principales necesarios, $Y_1, Y_2, \dots, Y_p$.

En primer lugar, se deberá comprobar que la matriz de distancias calculada cumpla con la propiedad euclídea. Es decir que tenga una representación euclídea de dimensión $p < n - 1$, si y solo si la matriz de productos internos (matriz de Gram) G es semidefinida positiva. Siendo: $G = -\frac{1}{2}HD^{(2)}H$, donde H es la matriz de centrado, $H = 1 - \frac{1}{n}11'$

Tras comprobar que la matriz de distancias original sí cumple con la propiedad euclídea, dado que los autovalores de la matriz G son no negativos, entonces se puede proceder a la obtención de las coordenadas principales. A continuación, se presenta una submatriz 5x5 de G, cuya dimensión original es 1000x1000.

El siguiente paso en la obtención de las coordenadas principales es diagonalizar la matriz de productos internos, tal que: $G = U\Lambda U'$, siendo Λ la matriz diagonal de autovalores de G tales que $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p \geq \lambda_{p+1} = \dots = \lambda_n = 0$. Los 5 primeros autovalores de G son: (148,25800; 122,83747; 59,37637; 54,64539; 47,84641). La matriz U se trata de una matriz $n \times p$ ortogonal cuyas columnas son los autovectores de G.

Finalmente, la matriz de coordenadas principales se obtiene como $Y = U\Lambda^{1/2}$. Para poder representarlo de manera que se pueda interpretar fácilmente y con claridad, se escogieron las 2 primeras coordenadas principales.

$$Y = \begin{bmatrix} -0,3744 & -0,05844 \\ 0,3219 & 0,2014 \\ -0,4636 & -0,3787 \\ -0,43 & -0,17 \\ 0,2356 & 0,08 \\ \dots & \dots \end{bmatrix}$$

A su vez se procedió a realizar una validación de la configuración espacial obtenida. Al comparar la matriz de distancias original frente a las distancias euclídeas calculadas utilizando el conjunto completo de coordenadas principales (n-1 dimensiones), se obtuvo un error máximo de 1.27×10^{-13} . Este valor, despreciable y atribuible únicamente al redondeo computacional, confirma que la matriz de distancias es euclídea y que las coordenadas principales obtenidas preservan con exactitud la métrica de Gower original.

Posteriormente, se calcularon los porcentajes de variabilidad explicada de las 2 coordenadas principales. $p_r = \frac{\lambda_1 + \dots + \lambda_r}{\lambda_1 + \dots + \lambda_p} \times 100$, $r = 2$.

Porcentajes de variabilidad explicada = (14,8258 ; 12,28375). En total, los 2 ejes suman explican un total de 27,11% de variabilidad explicada.

2.1. Representación gráfica de las coordenadas principales

Para visualizar la estructura latente de los hogares en el espacio reducido, se proyectaron los 1000 hogares de la muestra sobre el plano definido por las dos primeras coordenadas principales obtenidas del MDS clásico. La elección de dos dimensiones obedece tanto al criterio de interpretabilidad visual como al equilibrio entre variabilidad explicada y parsimonia: si bien el 27,11 % acumulado puede parecer modesto frente a los umbrales del PCA sobre variables cuantitativas puras, este valor es típico y esperado en un análisis MDS sobre datos mixtos. La presencia conjunta de variables binarias (Asalariado, Otros_ingresos) y categóricas con varias clases (Estudios, Tam_Municipio, Tam_Hogar) introduce ruido idiosincrático en las disimilitudes, que no puede comprimirse a baja dimensión sin pérdida de información estructural.

La decisión de colorear el mapa según la variable Asalariado, en lugar de Estudios u otra categórica, es metodológica: la separación que produce esta variable binaria sobre el primer eje del MDS es prácticamente perfecta, mientras que el resto de variables muestra un solapamiento sustancial entre niveles. El gráfico siguiente sintetiza la geometría que estructura toda la interpretación posterior.




Figura 1: Gráfico de Coordenadas Principales según la variable Asalariado

Este gráfico representa el **Mapa de coordenadas principales** (G-Gower MDS) coloreado por la variable Asalariado.

La inspección visual revela una segmentación nítida de la nube de puntos en dos macrorregiones a lo largo del primer eje, separadas por el origen. Los hogares con sustentador asalariado (Asalariado = 1, en color azul) se concentran en la región de coordenadas positivas del primer eje ($PCo1 > 0$), mientras que los hogares no asalariados (pensionistas, autónomos, inactivos, en color rojo) ocupan la región de coordenadas negativas ($PCo1 < 0$).

La separación es prácticamente binaria: el conteo cruzado entre el signo de $PCo1$ y la variable Asalariado coincide casi exactamente con la partición binaria original, lo que sugiere que el primer eje del MDS no representa un gradiente económico continuo, sino que actúa como una función indicadora del régimen laboral del sustentador principal. Este hallazgo, anticipado por la geometría, será confirmado cuantitativamente en la sección 2.3 mediante la V de Cramer.

A lo largo del segundo eje ($PCo2$) se observa una pequeña sub-nube de hogares atípicos en la franja superior ($PCo2 > 1,5$), separada visualmente de la masa principal de la muestra. Esta segregación vertical no responde al estado laboral —ambos colores aparecen tanto arriba como abajo— sino a otra dimensión que se identificará a partir de los gráficos cuantitativos.

2.2. Variabilidad explicada por las coordenadas principales

Para complementar la representación gráfica, se calcularon los porcentajes de variabilidad individual y acumulada asociados a cada coordenada principal. Solo los autovalores estrictamente positivos contribuyen a la variabilidad explicada en el sentido del MDS clásico; en este caso, los cinco primeros autovalores son 148,258; 122,837; 59,376; 54,645 y 47,846, lo que se traduce en porcentajes individuales de 14,83 %; 12,28 %; 5,94 %; 5,46 % y 4,78 %.

La caída marcada del 12,28 % ($PCo2$) al 5,94 % ($PCo3$) configura un "codo" entre la segunda y la tercera dimensión, justificando así la elección del plano $PCo1$ - $PCo2$ como subespacio de interpretación principal. Para alcanzar el umbral del 80 % de variabilidad acumulada se requieren más de 20 coordenadas, lo que confirma que la disimilitud entre hogares es genuinamente

multidimensional: la heterogeneidad asociada a las variables categóricas con múltiples clases distribuye la información residual en un espacio de dimensión efectiva alta. Este patrón es coherente con la teoría de MDS sobre distancias Gower generalizadas, donde la dimensión efectiva del espacio depende no solo del número de variables sino también del número total de categorías.




Figura 2: Gráfico de Porcentajes de Variabilidad Explicada y acumulada de las 20 Coordenadas Principales

2.3. Identificación de las variables subyacentes mediante correlaciones cruzadas

Para interpretar qué representan las dos coordenadas principales en términos de las variables originales, se calcularon medidas de asociación entre PCo1 y PCo2 y todas las variables del conjunto. A diferencia de un enfoque uniforme basado en la correlación de Pearson, se empleó una medida específica para cada tipo de variable, respetando la naturaleza de los datos:

- **Variables cuantitativas** (Gasto_Comida, Gasto_Vivienda, Gasto_Sanidad, Gasto_Ocio, Gasto_Restaurante, Gasto_total): correlación de Pearson, dado que tanto las coordenadas principales como las variables transformadas logarítmicamente son continuas.

$$\rho = \frac{\sigma_{xy}}{\sigma_x \sigma_y}$$

- **Variables binarias** (Otros_ingresos, Asalariado): V de Cramer, definida como $V = \sqrt{(\chi^2 / (n \cdot (\min(r,c)-1)))}$, donde las coordenadas principales se discretizan en 4 intervalos para construir la tabla de contingencia. La V de Cramer es no negativa ($V \in [0,1]$) y mide la intensidad de la dependencia, sin informar sobre dirección.
- **Variables ordinales** (Estudios, Tam_Municipio, Tam_Hogar): correlación de Spearman, apropiada para variables cuyo orden es informativo pero cuyas distancias entre categorías no son necesariamente equiespaciadas.

$$\rho_{sp} = 1 - \frac{6 \sum d_i^2}{n(n^2 - 1)}$$

Esta elección metodológica es preferible al uso uniforme de Pearson sobre códigos numéricos: aplicar Pearson sobre una variable binaria codificada como {0,1} produce un coeficiente cuyo valor depende del balance de la muestra, mientras que la V de Cramer es invariante a la codificación y captura únicamente la fuerza de la asociación. La tabla siguiente recoge las correlaciones obtenidas para las once variables del estudio.




Figura 3: Tabla de Correlaciones Cruzadas para las 2 primeras coordenadas principales

Interpretación de la primera coordenada principal (PCo1)

El hallazgo más destacado es la V de Cramer entre PCo1 y Asalariado, próxima a 0,99, una asociación prácticamente determinista. Aunque la V de Cramer no incorpora signo, la inspección visual del mapa de la sección 2.1 confirma la dirección: los asalariados ocupan PCo1 > 0 y los no asalariados PCo1 < 0. Este resultado constituye el hallazgo principal del análisis: la primera dimensión del MDS actúa, de facto, como una variable indicadora del estado laboral del sustentador principal del hogar. No representa un gradiente económico continuo, sino que separa dos regímenes laborales con perfiles de consumo cualitativamente diferenciados.

Las asociaciones secundarias de PCo1 son consistentes con esta interpretación. La correlación de Spearman positiva con Estudios ($\approx +0,46$) y con Tam_Hogar ($\approx +0,49$) indica que los hogares asalariados (PCo1 > 0) tienden a presentar mayor nivel educativo del sustentador y mayor tamaño de hogar; las correlaciones de Pearson positivas con Gasto_Restaurante ($\approx +0,37$) y Gasto_Ocio ($\approx +0,33$) apuntan a un patrón de consumo discrecional más intenso entre los asalariados. Por tanto, PCo1 puede caracterizarse como un eje sociolaboral que combina situación laboral, capital humano y capacidad de gasto discrecional.

Interpretación de la segunda coordenada principal (PCo2)

La segunda coordenada muestra un patrón de asociaciones radicalmente distinto y ortogonal al primero. La práctica nulidad de la V de Cramer entre PCo2 y Asalariado ($\approx 0,04$) confirma que ambos ejes son informativamente ortogonales: PCo2 captura una dimensión completamente independiente del estado laboral. La asociación dominante es la correlación de Pearson negativa con Gasto_Comida ($\approx -0,79$), reforzada por la inspección visual del gráfico cuantitativo: los hogares con PCo2 $> 1,5$ presentan valores de Gasto_Comida próximos a cero (color azul oscuro en la franja superior), mientras que la masa principal con PCo2 $< 0,5$ presenta valores moderado-altos (tonos amarillos y naranjas).




Figura 4: Gráfico de Coordenadas Principales según la variable Gasto en Comida.

Esta segunda dimensión segrega, por tanto, una pequeña sub-nube de hogares atípicos — probablemente con consumo de alimentación no registrado, en autoconsumo o con declaraciones agregadas— del cuerpo principal de la muestra. PCo2 no constituye un eje de interpretación socioeconómica primaria, sino un eje de control de calidad sobre el registro del gasto en alimentación. La interpretación de los perfiles principales se construirá, en consecuencia, sobre la masa principal de la muestra (PCo2 $< 0,5$).

2.4. Perfiles socioeconómicos en el espacio MDS

A partir de la geometría establecida en las secciones anteriores —PCo1 como eje sociolaboral binario y PCo2 como eje de control sobre el registro de Gasto_Comida— se identifican cuatro perfiles socioeconómicos por densidad de puntos en la masa principal del plano. Estos perfiles no son meras etiquetas: son arquetipos derivados del cruce entre la posición en el plano MDS y los gradientes coloreados de las variables más influyentes (aquellas con $|\text{correlación}| \geq 0,30$ según la Figura 3).

Las variables seleccionadas para la creación de estos perfiles fueron Gasto_Comida, Gasto_Ocio y Gasto_Restaurante en el bloque cuantitativo, y Asalariado, Estudios, Otros_ingresos y Tam_Hogar en el bloque cualitativo.

Perfil 1, Correspondiente a Consumo Discrecional e Inversión en Capital Humano

Localización en el plano MDS: cuadrante inferior-derecho ($PCo1 > 0$, $PCo2 < 0,5$), correspondiente a hogares asalariados de la masa principal. Este perfil concentra la subzona donde Gasto_Ocio y Gasto_Restaurante alcanzan los tonos más cálidos (rojos), Estudios = 4 (Educación Superior, con el color lila) presenta su máxima densidad y Tam_Hogar 3-4 domina, configurando el arquetipo de la clase media-alta urbana profesional.

La evidencia visual cruzada se articula en tres planos: el mapa de Asalariado (Figura 1) sitúa al perfil en la nube azul derecha; el gráfico de Estudios (Figura 5) muestra que la región $PCo1 > 0,2$ está saturada de puntos lila (Estudios = 4); y los gráficos de gasto discrecional (Figuras 6 y 8) revelan que esta misma región concentra los valores más altos de Gasto_Ocio (>7) y Gasto_Restaurante (>8). Tres señales independientes convergen sobre el mismo cuadrante geométrico, lo que avala la robustez de la caracterización.

Dinámica laboral y prioridades de consumo: sustentadores asalariados con alta estabilidad, beneficiados por el dinamismo del mercado laboral en 2024 y por la expansión del 13,9 % en gasto en servicios de educación reportada por el INE. La elasticidad-renta del consumo discrecional (ocio, restauración) es próxima a uno en este grupo, lo que explica su acumulación en la región del MDS donde estas variables presentan los valores máximos.

Esto plantea esta Hipótesis socioeconómica: clase media-alta urbana cualificada, gasto total elevado y consumo discrecional intenso.




Figura 5: Gráfico de Coordenadas Principales según la variable Nivel de Estudios

Esta imagen corresponde a la **Distribución de la variable Estudios sobre el plano MDS**. La concentración de Estudios = 4 (en color lila) en $PCo1 > 0,2$ ancla geométricamente al Perfil 1, como se puede observar.




Figura 6: Gráfico de Coordenadas Principales según la variable Gasto en Ocio

Este gráfico es el **Gradiente de Gasto_Ocio**. Los valores altos (rojo) saturan el cuadrante inferior-derecho, evidencia visual del Perfil 1.

Perfil 2 , Correspondiente a Supervivencia y Vulnerabilidad Estructural

Localización en el plano MDS: cuadrante inferior-izquierdo ($PCo1 < 0$, $PCo2 < 0,5$), en la subzona donde Gasto_Ocio y Gasto_Restaurante alcanzan los tonos más fríos (azules), Estudios = 1 (educación primaria, color rojo) presenta su máxima densidad y Tam_Hogar 1-2 (unipersonales y parejas, colores rojo y oliva) configura la mayoría de la nube. (ver Figura 6, Figura 8, Figura 9)

La evidencia visual cruzada es categórica: El mapa de Asalariado posiciona a estos hogares en la nube roja izquierda (no asalariados); el gráfico de Estudios muestra una concentración apreciable de puntos rojos (Estudios = 1) en $PCo1 < -0,4$; y los gráficos de gasto discrecional revelan que esta misma franja izquierda está saturada de puntos azules ($Gasto_Ocio < 4$ y $Gasto_Restaurante \approx 0$).

Este Perfil 2 representa, en consecuencia, a los hogares dependientes de pensiones, subsidios u otros ingresos no salariales, con sustentadores de baja cualificación y consumo cautivo en bienes de primera necesidad.

Restricción presupuestaria: el gasto discrecional es marginal o inexistente, lo que se traduce en una distancia euclídea apreciable respecto a los hogares asalariados sobre PCo1. Sensibilidad inflacionaria elevada: este perfil es el más afectado por el encarecimiento de alimentos y suministros básicos, dado que carece de margen de reasignación presupuestaria. Hipótesis socioeconómica: hogares con sustentador inactivo (pensionistas, rentistas de bajos recursos), bajo capital humano y consumo concentrado en supervivencia.




Figura 7: Gráfico de Coordenadas Principales según la variable Otros ingresos.

Este gráfico refleja la Distribución de la variable Otros_ingresos. Los hogares con Otros_ingresos = 1 (azul claro) se concentran en la parte central-baja, parcialmente solapando con el Perfil 2.




Figura 8: Gráfico de Coordenadas Principales según la variable Gasto en Restaurantes

Gradiente de Gasto_Restaurante. La saturación de azul oscuro en $PCo1 < -0,5$ confirma el consumo prácticamente nulo de este grupo en restauración.

Perfil 3, Correspondiente a Estabilidad Familiar en Municipios Medios

Localización en el plano MDS: subzona del cuadrante inferior-derecho (PCo1 entre 0,2 y 0,5, PCo2 $\approx$ 0), donde la variable Tam_Hogar exhibe sus valores intermedios y altos (3, 4, 5, son colores verde, cian y finalmente, azul). Este perfil comparte el lado asalariado del eje PCo1 con el Perfil 1, pero se distingue por una composición demográfica más numerosa y un patrón de gasto discrecional moderado en lugar de intenso.

La evidencia cruzada es sutil pero consistente: el gráfico de Tam_Hogar (Figura 9) muestra que la zona derecha del plano alberga, simultáneamente, hogares de tamaño 1 (rojo, Perfil 1 cuando se combinan con Estudios altos) y hogares de tamaño 3-4 (verde-cian) que son característicos del Perfil 3. Esta diferenciación interna del lado asalariado responde al ciclo de vida familiar: los hogares jóvenes asalariados con familias en formación presentan gasto total elevado por el número de miembros, pero gasto per cápita contenido, y un consumo en restauración moderado en comparación con los unipersonales urbanos del Perfil 1.

Vivienda y consumo: mayor probabilidad de vivienda en propiedad, lo que libera recursos para bienes duraderos y transporte. El consumo en hostelería es estable pero contenido, reflejando la recuperación post-pandemia con un peso aproximado del 5 % en el presupuesto total. Hipótesis socioeconómica: clase trabajadora estable de municipios medios, familias nucleares con consumo equilibrado.




Figura 9: Gráfico de Coordenadas Principales según la variable Tamaño del Hogar

Distribución de Tam_Hogar. La presencia de tonos cian-azul (3-5 miembros) en la región PCo1 $\in$ [0,2; 0,5] caracteriza geométricamente al Perfil 3.

Perfil 4, Correspondiente a La llamada “Generación Inquilina” y el Consumo de Servicios Urbanos

Este perfil posee una localización en el plano MDS: una banda diagonal que cruza ambos lados del eje PCo1, definida por Tam_Hogar = 1 (color rojo en la Figura 9) y Estudios = 4 (color lila en la Figura 5) coincidentes en el mismo punto. Una parte de este perfil aparece en el lado asalariado (PCo1 > 0) cuando se trata de profesionales jóvenes urbanos con empleo, y otra parte en el lado izquierdo (PCo1 < 0) cuando se trata de jóvenes con ingresos no salariales o situaciones laborales transitorias.

Este perfil presenta el conflicto de gasto más interesante de la muestra: alta cualificación educativa y consumo elevado en hostelería y cultura los acercaría al Perfil 1 sobre PCo1, pero la debilidad patrimonial y el peso del alquiler en el gasto total los aleja de la estabilidad del Perfil 3. La evidencia geométrica se construye por intersección: en la Figura 9, los puntos rojos (Tam_Hogar = 1) presentes simultáneamente en zonas con tonos lila intenso de la Figura 5 (Estudios = 4) constituyen el núcleo del perfil. Este cruce se localiza preferentemente en la mitad superior de la masa principal ($0 < \text{PCo2} < 0,5$), separando geométricamente al Perfil 4 del Perfil 1 (que ocupa la mitad inferior $\text{PCo2} < 0$).

Expectativas y dinámica residencial: este grupo muestra una alta percepción de riesgo inmobiliario; el acceso a vivienda en propiedad se percibe como una barrera estructural en 2024 dada la brecha entre formación de hogares (≈ 230.000 anuales) y oferta nueva (≈ 100.000). Su gasto se canaliza hacia servicios urbanos discrecionales como contraprestación por la imposibilidad de capitalizar el ahorro en activos inmobiliarios. Hipótesis socioeconómica: hogares unipersonales urbanos jóvenes con alta cualificación, gasto residencial intensivo y consumo de servicios elevado.

2.5. Conclusiones del análisis MDS

El Análisis de Coordenadas Principales mediante distancia G-Gower ha permitido identificar dos ejes ortogonales que estructuran el comportamiento de gasto de los hogares españoles en el espacio de datos mixtos.

En primer lugar, el primer eje (PCo1) actúa como una función indicadora del estado laboral del sustentador principal, con V de Cramer próxima a 0,99. Este resultado constituye el hallazgo principal del MDS: el primer eje no representa un gradiente económico continuo, sino que separa dos regímenes laborales asalariados frente a no asalariados con perfiles de consumo cualitativamente diferenciados, reforzados por las asociaciones secundarias con Estudios (Spearman $\approx +0,46$), Tam_Hogar (Spearman $\approx +0,49$), Gasto_Restaurante (Pearson $\approx +0,37$) y Gasto_Ocio (Pearson $\approx +0,33$).

En segundo lugar, el segundo eje (PCo2) captura una dimensión ortogonal al estado laboral, dominada por la asociación con Gasto_Comida (Pearson $\approx -0,79$). Este eje no constituye una dimensión socioeconómica primaria, sino un eje de control sobre la calidad del registro del gasto en alimentación, identificando una pequeña sub-nube de hogares atípicos en $\text{PCo2} > 1,5$.

La intersección los ambos ejes, restringida a la masa principal de la muestra, define cuatro perfiles socioeconómicos que articulan la realidad de los hogares españoles en 2024: el Perfil de Consumo Discrecional (clase media-alta urbana asalariada con alta cualificación), el Perfil de Supervivencia (no asalariados con baja cualificación y gasto cautivo), el Perfil de Estabilidad Familiar (clase trabajadora estable con familias nucleares en municipios medios) y el Perfil de la Generación Inquilina (jóvenes urbanos formados con consumo discrecional alto y debilidad patrimonial).

Estos perfiles complementan los hallazgos del PCA de la Tarea 2 donde la primera componente capturaba el volumen global de gasto al introducir las dimensiones laboral y de capital humano

como factores adicionales de segmentación del comportamiento de consumo familiar, y al revelar que la heterogeneidad de los hogares no es unidimensional sino estructurada en torno a regímenes laborales y trayectorias residenciales diferenciadas.

3. CLASIFICACIÓN JERÁRQUICA

Una vez finalizado el Análisis de Coordenadas Principales, se procedió a aplicar una técnica de clasificación sobre los hogares de la muestra. El objetivo de este segundo análisis no es sustituir la interpretación geométrica obtenida mediante el MDS, sino complementarla mediante una agrupación formal de los individuos a partir de sus similitudes globales.

La elección de una **clasificación jerárquica aglomerativa** resulta coherente con el procedimiento desarrollado en los apartados anteriores, ya que se dispone previamente de una matriz de distancias entre hogares.

En este caso se utilizó la misma matriz de distancias **G-Gower** calculada al inicio del trabajo. Esta distancia resulta adecuada porque combina información de variables de distinta naturaleza: variables cuantitativas de gasto, variables binarias y variables categóricas. En concreto, en el trabajo se emplea la distancia de Mahalanobis para las variables cuantitativas, la distancia asociada al coeficiente de Jaccard para las binarias y la distancia de Hamming para las categóricas, integrándolas en la distancia G-Gower

Como la matriz obtenida anteriormente corresponde a distancias al cuadrado, antes de aplicar la clasificación jerárquica se tomó la raíz cuadrada de sus elementos. Aquí se insertan la submatriz 5x5 de la matriz de distancias original:


$$D = \begin{bmatrix} 0 & 1,427 & 1,462 & 1,375 & 1,34 \\ 1,427 & 0 & 1,55 & 1,27 & 0,99 \\ 1,462 & 1,55 & 0 & 1,487 & 1,55 \\ 1,375 & 1,27 & 1,487 & 0 & 1,418 \\ 1,34 & 0,99 & 1,55 & 1,418 & 0 \end{bmatrix}$$

Posteriormente, se aplicó el método de Ward mediante la función de ‘hclust’ de R. El método de Ward busca formar grupos internamente homogéneos, minimizando el incremento de la variabilidad dentro de los grupos en cada etapa de fusión. A diferencia de los métodos clásicos de enlace simple o completo, que basan la fusión en las distancias entre los individuos más cercanos o más lejanos de cada grupo respectivamente, Ward utiliza un criterio global de optimización de la varianza, lo que lo hace menos sensible a valores atípicos y produce clústeres más equilibrados en tamaño. Por ello, resulta especialmente adecuado cuando se desea obtener clases compactas, equilibradas y fácilmente interpretables, como es el caso del presente análisis.

3.1. Elección del número de grupos

Para proceder a la elección del número de grupos lo más habitual es representar las agrupaciones por medio de un dendograma, pero debido a la gran cantidad de individuos que se debían representar (1000), el resultado es difícilmente interpretable. Por lo tanto, se decidió trabajar con tres grupos por razones de interpretación y síntesis. La elección de k=3 se apoya en el Gráfico de Codo obtenido a partir de las alturas de fusión del método de Ward. En dicho gráfico se observan dos caídas pronunciadas: la primera al pasar de k=1 a k=2, y la segunda, también notable, al pasar de k=2 a k=3. A partir de k=3 la curva se aplanar de forma clara, indicando que incrementar el número de clústeres produce ganancias marginales pequeñas en la reducción de la varianza

intragrupo. Este punto de inflexión señala $k=3$ como el número de grupos más adecuado y estadísticamente justificado.



Aunque en el análisis MDS se habían identificado cuatro perfiles socioeconómicos en el plano bidimensional, dichos perfiles procedían de una interpretación visual y sustantiva de las dos primeras coordenadas principales. En cambio, la clasificación jerárquica se basa en la matriz completa de distancias entre los 1000 hogares. Por tanto, no es necesario que exista una correspondencia exacta entre los cuatro perfiles interpretativos del MDS y los grupos obtenidos por clasificación. El MDS busca representar gráficamente la estructura de distancias, mientras que la clasificación jerárquica busca construir grupos homogéneos de hogares.

Además, debe recordarse que el plano formado por las dos primeras coordenadas principales explica el 27,11% de la variabilidad total, por lo que resume una parte relevante, pero no completa, de la estructura de disimilitudes entre hogares. Por ello, la clasificación jerárquica aporta una visión complementaria al utilizar la información completa de la matriz de distancias.

3.2. Resultados de la clasificación

La clasificación jerárquica permitió obtener tres grupos de hogares con tamaños claramente diferenciados:

Grupo	Número de hogares	Porcentaje
Grupo 1	359	35,9%
Grupo 2	21	2,1%
Grupo 3	620	62,0%




Figura 10. Tamaño de los grupos obtenidos mediante clasificación jerárquica.

La Figura 10 muestra que el **Grupo 3** es el más numeroso, con 620 hogares, seguido del **Grupo 1**, con 359 hogares. El **Grupo 2** presenta un tamaño muy reducido, con solo 21 hogares, lo que sugiere que recoge observaciones con un comportamiento más específico o atípico.

Las medias de gasto por grupo fueron las siguientes

Grupo	Comida	Vivienda	Sanidad	Ocio	Restaurantes	Gasto total
Grupo 1	4907,425	11238,142	1509,484	1169,489	1873,489	28729,063
Grupo 2	0,0	9987,249	3087,478	620,331	5865,696	27381,825
Grupo 3	6105,893	11034,261	1634,404	2382,073	4475,517	38375,386




Figura 11. Heatmap del perfil medio de gasto por grupo.

La Figura 11 resume las diferencias de gasto entre los tres grupos mediante medias estandarizadas. El **Grupo 3** destaca por sus valores superiores en gasto total, comida y ocio, lo que permite asociarlo con hogares de mayor intensidad de consumo. Este resultado es coherente con los perfiles de consumo discrecional y estabilidad familiar descritos en el MDS, donde los hogares asalariados de la zona derecha del plano presentaban mayor consumo en ocio y restauración.

El **Grupo 1** presenta un perfil de gasto más moderado. Aunque su gasto en vivienda es similar al del Grupo 3, registra valores inferiores en ocio, restaurantes y gasto total. Por ello, puede interpretarse como un grupo de hogares con menor consumo discrecional, más próximo al perfil de supervivencia y vulnerabilidad estructural identificado en el MDS.

El **Grupo 2** debe interpretarse con cautela, ya que contiene únicamente 21 hogares. Su rasgo más llamativo es el gasto medio nulo en comida y un gasto relativamente elevado en sanidad y restaurantes. Este comportamiento encaja con la sub-nube atípica detectada en el MDS sobre el eje PCo2, donde se señalaba que algunos hogares presentaban valores de Gasto_Comida próximos a cero. En el análisis MDS, este segundo eje fue interpretado como una dimensión de control de calidad del registro del gasto en alimentación, más que como un eje socioeconómico primario.

3.3. Perfil cualitativo de los grupos

Además de las variables de gasto, se analizaron las variables binarias y categóricas para caracterizar mejor cada grupo. En particular, la variable **Asalariado** resulta especialmente importante, ya que en el análisis MDS se había observado que la primera coordenada principal

separaba casi perfectamente a los hogares asalariados de los no asalariados. En concreto, los hogares asalariados se situaban en la región positiva de PCo1, mientras que los no asalariados ocupaban la región negativa

La tabla siguiente recoge las proporciones de hogares con otros ingresos y de hogares asalariados en cada grupo:

Grupo	Proporción con otros ingresos	Proporción asalariados
Grupo 1	0,3 %	0,0%
Grupo 2	0,0 %	71,4%
Grupo 3	3,7 %	98,5%




Figura 12. Heatmap de las variables laborales por grupo.

La Figura 12 muestra que la variable **Asalariado** diferencia claramente los grupos. El **Grupo 1** está formado prácticamente por hogares no asalariados, mientras que el **Grupo 3** está compuesto casi en su totalidad por hogares asalariados. Este resultado confirma la importancia de la dimensión sociolaboral ya detectada en el MDS, donde la primera coordenada principal actuaba prácticamente como una variable indicadora del régimen laboral del sustentador principal.

El **Grupo 2** presenta una proporción elevada de hogares asalariados, aunque inferior a la del Grupo 3. Sin embargo, debido a su reducido tamaño, no debe interpretarse como un perfil general de la población, sino como un grupo específico con un patrón particular de gasto.

3.4. Comparación con el análisis MDS

La clasificación jerárquica confirma varios de los resultados obtenidos en el Análisis de Coordenadas Principales. En primer lugar, vuelve a aparecer una fuerte separación entre hogares asalariados y no asalariados, especialmente visible en la composición de los Grupos 1 y 3. Este

resultado es coherente con la interpretación del primer eje del MDS, donde PCo1 separaba dos regímenes laborales claramente diferenciados.

En segundo lugar, la clasificación identifica un grupo pequeño de hogares con características atípicas, el Grupo 2. Este grupo se relaciona con la interpretación del segundo eje del MDS, asociado principalmente al gasto en comida. En el MDS, PCo2 no se interpretaba como un eje socioeconómico primario, sino como una dimensión vinculada a registros muy bajos o nulos de gasto en alimentación.

Por tanto, las agrupaciones obtenidas mediante clasificación jerárquica guardan una relación clara con la estructura observada en el MDS, aunque no la reproducen de forma exacta. El MDS permitió construir cuatro perfiles socioeconómicos interpretativos: consumo discrecional, supervivencia, estabilidad familiar y generación inquilina. La clasificación jerárquica, en cambio, resume la estructura global en tres grupos estadísticos. Esta diferencia es razonable, ya que ambos métodos tienen objetivos distintos: el MDS representa gráficamente las distancias, mientras que la clasificación agrupa hogares según su similitud global.

3.5. Hipótesis y condiciones de aplicación

Para aplicar correctamente la clasificación jerárquica se han considerado varias condiciones. En primer lugar, la matriz de distancias debe ser simétrica, no negativa y con diagonal nula. En segundo lugar, al utilizar el método de Ward, resulta conveniente trabajar con distancias euclídeas o aproximadamente euclídeas, ya que este método se basa en minimizar la variabilidad interna de los grupos.

En el apartado anterior se comprobó que la matriz de distancias utilizada admitía una representación euclídea mediante el Análisis de Coordenadas Principales. Además, el error máximo al comparar las distancias originales con las distancias reconstruidas usando todas las coordenadas principales fue prácticamente nulo, lo que confirma que la configuración obtenida preserva adecuadamente la métrica original

También se asume que las variables seleccionadas son relevantes para caracterizar a los hogares y que el tratamiento previo aplicado a las variables cuantitativas, mediante reescalado y transformación $\log(x+1)$ reduce los problemas de asimetría y heterocedasticidad indicados en la introducción del trabajo.

3.6. Conclusiones de la clasificación

La clasificación jerárquica ha permitido identificar tres grupos principales de hogares. El **Grupo 1** recoge hogares con menor presencia de asalariados y con un patrón de gasto más moderado, especialmente en ocio y restauración. El **Grupo 2** es un grupo pequeño y atípico, caracterizado por un gasto nulo en comida y valores relativamente elevados en sanidad y restaurantes. El **Grupo 3** es el más numeroso y se caracteriza por una presencia casi total de hogares asalariados y por mayores niveles de gasto total y consumo discrecional.

En conjunto, la clasificación jerárquica refuerza las conclusiones obtenidas mediante el MDS. Ambos análisis muestran que la situación laboral del sustentador principal y determinados patrones de gasto, especialmente en comida, ocio y restaurantes, son factores clave para explicar la heterogeneidad de los hogares. Así, la clasificación proporciona una validación adicional de la estructura detectada previamente en el espacio de coordenadas principales.

BIBLIOGRAFÍA

Álvarez M, Boj E, Grané A (2025). dbrobust: Robust Distance-Based Visualization and Analysis of Mixed-Type Data. doi:10.32614/CRAN.package.dbrobust
<<https://doi.org/10.32614/CRAN.package.dbrobust>>, R package version 1.0.0,
<<https://CRAN.R-project.org/package=dbrobust>>.

Grané, A. (2026). *Tema 6. Análisis de Coordenadas Principales*. [Apuntes de clase]. Aula Global, Universidad Carlos III de Madrid.
<https://aulaglobal.uc3m.es/mod/resource/view.php?id=5791368>

Grané, A. (2026). *Tema 7. Análisis de Conglomerados (Cluster)*. [Apuntes de clase]. Aula Global, Universidad Carlos III de Madrid.
<https://aulaglobal.uc3m.es/mod/resource/view.php?id=5791369>

Hadley Wickham (2007). Reshaping Data with the reshape Package. Journal of Statistical Software, 21(12), 1-20. URL <http://www.jstatsoft.org/v21/i12/>.

R Core Team (2025). R: A Language and Environment for Statistical Computing. R Foundation for Statistical Computing, Vienna, Austria. <<https://www.r-project.org/>>

Wickham H (2016). *ggplot2: Elegant Graphics for Data Analysis*. Springer-Verlag New York. ISBN 978-3-319-24277-4, <https://ggplot2.tidyverse.org>.

ANEXO: CÓDIGO R

```
# TAREA 3 - TRABAJO ANÁLISIS MULTIVARIANTE
#-----
library(ggplot2)

library(dbrobust)

library(reshape2)

load("EPFhogar_2024.RData")

datos <- Microdatos

datos_sub <- datos[, c(
  "GASTOTGR01", "GASTOTGR04", "GASTOTGR06", "GASTOTGR09",
  "GASTOTGR11", "GASTOT", "OTROIN",
  "CAJENA", "ESTUDREDSP", "TAMAMU", "TAMANO"
)]

colnames(datos_sub) <- c(
  "Gasto_Comida", "Gasto_Vivienda", "Gasto_Sanidad", "Gasto_Ocio",
  "Gasto_Restaurante", "Gasto_total", "Otros_ingresos",
  "Asalariado", "Estudios", "Tam_Municipio", "Tam_Hogar"
)

datos_limpios <- datos_sub

datos_limpios$Otros_bin <- ifelse(datos_limpios$Otros_ingresos == 1,
1, 0)
datos_limpios$Asalariado_bin <- ifelse(datos_limpios$Asalariado == 1,
1, 0)

datos_limpios$Estudios <- as.factor(datos_limpios$Estudios)
datos_limpios$Tam_Municipio <- as.factor(datos_limpios$Tam_Municipio)
datos_limpios$Tam_Hogar <- as.factor(datos_limpios$Tam_Hogar)

datos_limpios$Asalariado <- NULL
datos_limpios$Otros_ingresos <- NULL

set.seed(1234)
filas <- sample(nrow(datos_limpios), 1000)
datos_final <- datos_limpios[filas, ]

str(datos_final)

summary(datos_final)
```

```

datos_num <- datos_final[, sapply(datos_final, is.numeric)]
vars_continuas <- c("Gasto_Comida", "Gasto_Vivienda", 'Gasto_Sanidad',
"Gasto_Ocio",
                    'Gasto_Restaurante', "Gasto_total")

datos_num[vars_continuas] <- datos_num[vars_continuas] / 1000

datos_trans <- datos_num
datos_trans[vars_continuas] <- log(datos_trans[vars_continuas]+1)
datos_trans_n <- as.matrix(datos_trans[, vars_continuas])
datos_trans$Estudios <- datos_final$Estudios
datos_trans$Tam_Municipio <- datos_final$Tam_Municipio
datos_trans$Tam_Hogar <- datos_final$Tam_Hogar

D2 <- dbrobust::robust_distances(datos_trans, p = c(6,2,3), method = "
ggower", return_dist = FALSE)

#-----

# ANÁLISIS DE COORDENADAS PRINCIPALES - MDS
D <- sqrt(D2)
n <- nrow(D2)
H <- diag(n) - (1/n) * matrix(1, nrow = n, ncol = n)
G <- (-1/2) * H %*% D2 %*% H

L <- eigen(G, symmetric = TRUE, only.values = TRUE)$values
m <- min(L)
epsilon <- 1e-6
if (abs(m) > epsilon) {
  D <- D2 - (2 * m * matrix(1, nrow = n, ncol = n)) + (2 * m * diag
(n))
  G <- (-1/2) * H %*% D %*% H
}

MDS <- cmdscale(D, k = 2, eig = TRUE)

Y <- MDS$points
colnames(Y) <- c("Dim1", "Dim2")

vaps <- MDS$eig
percent <- (vaps/sum(abs(vaps)))*100
acum <- cumsum(percent)

print(paste0("Varianza total explicada: ", round(percent[1] + percent
[2], 2), "%"))

## [1] "Varianza total explicada: 27.11%"

U = eigen(G)$vectors

n <- nrow(as.matrix(D2))
MDS_completo <- cmdscale(sqrt(D2), k = n - 1, eig = TRUE)

Y_total <- MDS_completo$points
dist_mapa <- as.matrix(dist(Y_total))

```

```

dist_original <- sqrt(D2)
diferencia <- max(abs(dist_original - dist_mapa))
print(paste("Diferencia con todas las dimensiones:", diferencia))

## [1] "Diferencia con todas las dimensiones: 1.27009514017118e-13"

```

Representación Gráfica

```

plot(Y[, 1], Y[, 2],
     col = "blue", pch = 16, cex = 1.5,
     xlab = "Primera coordenada principal",
     ylab = "Segunda coordenada principal",
     main = paste0("Porcentaje de variab. explicada ", round(acum[2],
2), "%"),
     panel.first = grid())

```

```

if (n <= 100) {
  text(Y[, 1], Y[, 2], labels = 1:n, pos = 3, cex = 0.8)
}

```

```

df_var <- data.frame(
  Coord = seq_along(percent),
  Indiv = percent,
  Acum = acum
)

```

```

ggplot(df_var[1:20, ], aes(x = Coord)) +
  geom_col(aes(y = Indiv), fill = "steelblue", alpha = 0.7, width = 0.
7) +
  geom_line(aes(y = Acum), color = "firebrick", linewidth = 1.2) +
  geom_point(aes(y = Acum), color = "firebrick", size = 3) +
  geom_hline(yintercept = 80, linetype = 2, color = "grey50", linewidth
h = 0.8) +
  scale_x_continuous(breaks = 1:20) +
  labs(
    title = "Porcentaje de variabilidad explicada y acumulada",
    subtitle = "Primeras 20 coordenadas principales",
    x = "Coordenada principal",
    y = "% de variabilidad"
  ) +
  theme_bw() +
  theme(
    plot.title = element_text(hjust = 0.5, face = "bold"),
    plot.subtitle = element_text(hjust = 0.5)
  )

```

CORRELACIONES CRUZADAS

```

p <- ncol(datos_trans)

```



```

k <- 2 ; pcuant <- 6 ; pnominal <- 2 ; pordinal <- p - pcuant - pnominal

# --- V de Cramer ---
CramerV <- function(x, y, bins = 4) {
  y_cat <- cut(y, breaks = bins, labels = FALSE, include.lowest = TRUE)
  tbl <- table(x, y_cat)
  chi2 <- suppressWarnings(chisq.test(tbl)$statistic)
  n <- sum(tbl)
  k_loc <- min(nrow(tbl), ncol(tbl))
  v <- sqrt(chi2 / (n * (k_loc - 1)))
  return(as.numeric(v))
}

corr_table <- matrix(0, nrow = p, ncol = k)

# 1. Pearson para cuantitativas
if (pcuant > 0) {
  corr_table[1:pcuant, ] <- cor(
    datos_trans[, 1:pcuant, drop = FALSE],
    Y[, 1:k, drop = FALSE],
    method = "pearson"
  )
}

# 2. V de Cramer para nominales
if (pnominal > 0) {
  idx <- (pcuant + 1):(pcuant + pnominal)
  for (col_i in idx) {
    corr_table[col_i, ] <- sapply(
      1:k,
      function(j) CramerV(datos_trans[, col_i], Y[, j])
    )
  }
}

# 3. Spearman para ordinales
if (pordinal > 0) {
  ord_cols <- (pcuant + pnominal + 1):p
  datos_ordinales_num <- data.frame(lapply(datos_trans[, ord_cols], function(x) as.numeric(as.factor(x)))))
  corr_table[ord_cols, ] <- cor(datos_ordinales_num, Y[, 1:k], method = "spearman", use = "complete.obs")
}

colnames(corr_table) <- paste0("PC", 1:k) # "PC1", "PC2" (o hasta k)
rownames(corr_table) <- colnames(datos_trans)

# --- Heatmap ---
my_colors <- c(
  "#0000CC", "#0066FF", "#66CCFF",
  "#FFFFFF",
  "#FF99FF", "#FF33CC", "#800080"
)

```

```

)

df <- melt(corr_table)
colnames(df) <- c("Variable", "PC", "value")

p_heatmap <- ggplot(df, aes(x = PC, y = Variable, fill = value)) +
  geom_tile(color = "white") +
  scale_fill_gradientn(
    colors = my_colors,
    limits = c(-1, 1),
    name = ""
  ) +
  geom_text(aes(label = round(value, 2)), size = 3) +
  labs(title = "Principal Coordinates Heatmap") +
  theme_minimal(base_size = 12) +
  theme(
    plot.title = element_text(hjust = 0.5, size = 12),
    axis.title = element_blank()
  )

print(p_heatmap)

# --- PERFILES: VARIABLES CUANTITATIVAS ---
umbral <- 0.3
var_names <- colnames(datos_trans)[1:pcuant]

max_corr <- apply(abs(corr_table[1:pcuant, ]), 1, max)
vars_sel <- which(max_corr >= umbral)
cat("Variables seleccionadas:", names(vars_sel))

## Variables seleccionadas: Gasto_Comida Gasto_Ocio Gasto_Restaurante

if (!dir.exists("plots_cuantis")) dir.create("plots_cuantis")

for (j in vars_sel) {
  df <- data.frame(PCo1 = Y[, 1], PCo2 = Y[, 2], valor = datos_trans[,
j])

  fig <- ggplot(df, aes(x = PCo1, y = PCo2, color = valor)) +
    geom_point(size = 2.5) +
    scale_color_distiller(palette = "RdYlBu", name = var_names[j]) +
    labs(title = paste("Variable cuantitativa:", var_names[j]),
         x = "PCo1", y = "PCo2") +
    theme_minimal(base_size = 11) +
    theme(plot.title = element_text(hjust = 0.5, face = "bold"))

  print(fig)
  ggsave(file.path("plots_cuantis", paste0(var_names[j], ".png")),
         plot = fig, width = 6, height = 5, dpi = 150)
}

# =====
=====

```

```

# GRÁFICAS DE LA CLASIFICACIÓN JERÁRQUICA

# =====

library(ggplot2)
library(reshape2)

# Carpeta donde se guardarán las figuras
carpeta_cluster <- "graficas_clasificacion_estilo_companeros"

if (!dir.exists(carpet_cluster)) {
  dir.create(carpet_cluster)
}

# -----
# -----

# 1. Preparación de tablas para las gráficas
# -----
# -----

# Como D2 contiene distancias al cuadrado, usamos la raíz cuadrada para
# a hclust
D <- as.dist(sqrt(pmax(D2, 0)))

# Clasificación jerárquica aglomerativa mediante Ward
clasif_jer <- hclust(D, method = "ward.D2")

# Corte en 3 grupos
k <- 3
grupos <- cutree(clasif_jer, k = k)

ultimas <- tail(clasif_jer$height, 15)
codo <- plot(rev(ultimas), type = "b", pch = 19,
            xlab = "Número de clústeres",

```

```

        ylab = "Altura de fusión",
        main = "Criterio de Ward - Selección de k")
print(codo)

# Base con Los grupos añadidos
datos_perfil <- datos_trans
datos_perfil$Grupo <- as.factor(grupos)

# Tabla de tamaños de grupo
df_tam <- as.data.frame(table(datos_perfil$Grupo))
colnames(df_tam) <- c("Grupo", "Frecuencia")

# Tabla de medias de gasto por grupo
medias_gasto_grupo <- aggregate(
  datos_perfil[, vars_continuas],
  by = list(Grupo = datos_perfil$Grupo),
  FUN = mean
)

# Tabla de proporciones laborales
prop_otros <- prop.table(table(datos_perfil$Grupo, datos_perfil$Otros_
bin), 1)

prop_asal <- prop.table(table(datos_perfil$Grupo, datos_perfil$Asalari
ado_bin), 1)

df_laboral <- data.frame(
  Grupo = levels(datos_perfil$Grupo),
  Otros_ingresos = prop_otros[, "1"],
  Asalariado = prop_asal[, "1"]
)

```

```

# -----
# -----

# 2. Paleta de colores parecida a la usada en el MDS

# -----
# -----

col_grupos <- c("#F8766D", "#7CAE00", "#00BFC4")

my_colors <- c(
  "#0000CC", "#0066FF", "#66CCFF",
  "#FFFFFF",
  "#FF99FF", "#FF33CC", "#800080"
)

# =====
# =====

# FIGURA 10. Tamaño de Los grupos

# =====
# =====

p_tam <- ggplot(df_tam, aes(x = Grupo, y = Frecuencia, fill = Grupo))
+
  geom_col(color = "white", width = 0.75) +
  geom_text(aes(label = Frecuencia), vjust = -0.4, size = 3.5) +
  scale_fill_manual(values = col_grupos) +
  labs(
    title = "Clasificación jerárquica: tamaño de Los grupos",
    x = "Grupo",
    y = "Número de hogares"
  ) +
  theme_minimal(base_size = 11) +
  theme(
    plot.title = element_text(hjust = 0.5, face = "bold"),

```

```

    legend.position = "none",
    panel.grid.minor = element_blank()
)

print(p_tam)

ggsave(
  filename = file.path(carpeta_cluster, "10_tamano_grupos_estilo_compa
neros.png"),
  plot = p_tam,
  width = 6,
  height = 5,
  dpi = 300
)

# =====
# =====

# FIGURA 8. Heatmap del perfil medio de gasto por grupo

# =====
# =====

# Estandarizamos las medias por variable para comparar perfiles en una
misma escala

medias_z <- medias_gasto_grupo

for (v in vars_continuas) {
  medias_z[[v]] <- as.numeric(scale(medias_gasto_grupo[[v]]))
}

# Pasamos a formato largo para ggplot
df_heat_gasto <- melt(
  medias_z,

```

```

    id.vars = "Grupo",
    variable.name = "Variable",
    value.name = "Media_estandarizada"
  )

p_heat_gasto <- ggplot(
  df_heat_gasto,
  aes(x = Grupo, y = Variable, fill = Media_estandarizada)
) +
  geom_tile(color = "white") +
  geom_text(aes(label = round(Media_estandarizada, 2)), size = 3) +
  scale_fill_gradientn(
    colors = my_colors,
    limits = c(-1.5, 1.5),
    name = "Media\nestandarizada"
  ) +
  labs(title = "Cluster Profile Heatmap") +
  theme_minimal(base_size = 11) +
  theme(
    plot.title = element_text(hjust = 0.5, face = "bold"),
    axis.title = element_blank(),
    panel.grid = element_blank()
  )

print(p_heat_gasto)

ggsave(
  filename = file.path(carpeta_cluster, "11_heatmap_perfil_gasto_grupo
s.png"),
  plot = p_heat_gasto,
  width = 6,

```

```

    height = 6,
    dpi = 300
)

# =====
# =====

# FIGURA 9. Perfil medio estandarizado de gasto por grupo
# Esta figura es opcional. Sirve como alternativa al heatmap.
# =====
# =====

p_perfil <- ggplot(
  df_heat_gasto,
  aes(
    x = Variable,
    y = Media_estandarizada,
    group = Grupo,
    color = Grupo
  )
) +
  geom_line(linewidth = 1) +
  geom_point(size = 2.5) +
  scale_color_manual(values = col_grupos) +
  labs(
    title = "Perfil medio de gasto por grupo",
    x = "Variable de gasto",
    y = "Media estandarizada"
  ) +
  theme_minimal(base_size = 11) +
  theme(
    plot.title = element_text(hjust = 0.5, face = "bold"),

```



```

    axis.text.x = element_text(angle = 45, hjust = 1),
    panel.grid.minor = element_blank()
)

print(p_perfil)

ggsave(
  filename = file.path(carpeta_cluster, "12_perfil_medio_gasto_estilo_
companeros.png"),
  plot = p_perfil,
  width = 8,
  height = 5.5,
  dpi = 300
)

# =====
# =====

# FIGURA 10. Heatmap de variables laborales por grupo

# =====
# =====

df_laboral_largo <- melt(
  df_laboral,
  id.vars = "Grupo",
  variable.name = "Variable",
  value.name = "Proporcion"
)

# Cambiamos nombres para que salgan más bonitos en la gráfica
df_laboral_largo$Variable <- factor(
  df_laboral_largo$Variable,
  levels = c("Otros_ingresos", "Asalariado"),

```

```

    labels = c("Otros ingresos", "Asalariado")
)

p_heat_laboral <- ggplot(
  df_laboral_largo,
  aes(x = Grupo, y = Variable, fill = Proporción)
) +
  geom_tile(color = "white") +
  geom_text(aes(label = round(Proporción, 2)), size = 3.5) +
  scale_fill_gradientn(
    colors = my_colors,
    limits = c(0, 1),
    name = "Proporción"
  ) +
  labs(title = "Variables cualitativas por grupo") +
  theme_minimal(base_size = 11) +
  theme(
    plot.title = element_text(hjust = 0.5, face = "bold"),
    axis.title = element_blank(),
    panel.grid = element_blank()
  )

print(p_heat_laboral)

ggsave(
  filename = file.path(carpeta_cluster, "13_heatmap_variables_laborales_grupos.png"),
  plot = p_heat_laboral,
  width = 6,
  height = 4,
  dpi = 300)

```